



Session 02

Data Exploration with Google Colab

Data Analysis with AI

Asst. Prof. Taweesak Samanchuen, Ph.D.

Mahidol University

วัตถุประสงค์ของ Session

เมื่อจบช่วงนี้ ผู้เข้าอบรมสามารถ:

1. เริ่มใช้งาน Google Colab ได้ แม้ไม่เคยใช้งานมาก่อน
2. เข้าใจบทบาทของ AI ภายใน workflow การวิเคราะห์ข้อมูลใน Colab
3. แปลงโจทย์เชิงนโยบายเป็นคำถามเชิงข้อมูลได้
4. ตรวจสอบและเตรียมข้อมูลก่อนวิเคราะห์ได้เป็นระบบ
5. ใช้ Generative AI ช่วยสำรวจข้อมูลเบื้องต้นได้

สารบัญ

1. Colab สำหรับผู้เริ่มต้น
2. Basic Python + AI Prompting for Data Analysis
3. Data Preparation & Quality Check
4. Exploratory Data Analysis (EDA)
5. Workshop Pipeline Series
 - Workshop 2: Titanic Quick Start
 - Workshop 3: Data Preparation Pipeline
 - Workshop 5: Population Statistics (NSO)
 - Workshop 6: Household Finance (NSO)

Colab สำหรับผู้เริ่มต้น

Colab คืออะไร ทำไมต้องใช้ Colab ในการวิเคราะห์ข้อมูลด้วย AI

Colab คืออะไร

- แพลตฟอร์มโน้ตบุ๊กออนไลน์ที่ Google ให้บริการฟรี
- รองรับการเขียนโค้ด Python และการใช้ AI ช่วยเขียนโค้ดได้ในทีเดียว
- เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความยืดหยุ่นและตรวจสอบได้

สิ่งที่ผู้เรียนส่วนใหญ่กังวล

- ไม่เคยเขียนโค้ดมาก่อน
- ไม่แน่ใจว่าจะเริ่มจากปุ่มไหน
- กลัวพิมพ์ผิดแล้วใช้งานต่อไม่ได้



ทำไม Session นี้ต้องใช้ Colab (ไม่ใช่ AI Chat โดยตรง)

เหตุผลหลัก

1. **ทำงานวิเคราะห์ได้จริง:** Colab ช่วยให้เราทำงานกับข้อมูลจริงได้ ตั้งแต่การโหลดข้อมูล, ทำความสะอาด, วิเคราะห์ และสร้างกราฟในที่เดียว
2. **ตรวจสอบได้:** ทุกขั้นตอนการวิเคราะห์ถูกบันทึกใน Notebook เดียว ทำให้สามารถตรวจสอบย้อนกลับและทำซ้ำได้ง่าย
3. **เรียนรู้การใช้ AI ใน workflow จริง:** การใช้ AI ช่วยเขียนโค้ดใน Colab เป็นทักษะที่สำคัญในการทำงานวิเคราะห์ข้อมูลยุคใหม่ ซึ่งไม่สามารถเรียนรู้ได้จากการใช้ AI Chat อย่างเดียว

สรุป

AI Chat อย่างเดียว "ตอบได้เร็ว" แต่ Colab + AI "ทำงานวิเคราะห์ได้จริงและตรวจสอบได้"

เปรียบเทียบ: AI Chat โดยตรง vs Colab + AI

ประเด็น	AI Chat โดยตรง	Colab + AI
การเก็บขั้นตอน	กระจัดกระจายตามบทสนทนา	อยู่ใน Notebook เดียว
การทำซ้ำผลลัพธ์	ทำได้ยาก	ทำได้ง่าย (Run all)
การตรวจสอบย้อนกลับ	จำกัด	ชัดเจนและตรวจสอบได้
ความพร้อมใช้งานหน้างาน	ปานกลาง	สูง

สรุป: Colab + AI เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความถูกต้องและตรวจสอบได้ ในขณะที่ AI Chat เหมาะสำหรับการตอบคำถามหรือสร้างโค้ดอย่างรวดเร็วในขั้นตอนแรก

Workshop 1: Quick Start Colab (สำหรับผู้เริ่มต้น)

5 ขั้นตอนแรกที่ต้องทำ

1. ไปที่ <https://colab.research.google.com/> และเลือก "New Notebook"
2. ตั้งชื่อไฟล์ให้สื่อความหมายของโจทย์
3. ทดลองใช้งาน Code Cell: เช่น `x = 10; y = 20; print(x + y)`
4. ทดลองใช้งาน Text Cell: เขียนคำอธิบายสั้นๆ ว่า "นี่คือการทดสอบ Text Cell"
5. ทดลอง upload ข้อมูล : presidents.csv จากเครื่องขึ้น Colab (ไอคอนโฟลเดอร์ > Upload)
https://github.com/toche7/DataSets/blob/main/president_heights.csv
6. รันโค้ดอ่านไฟล์ด้วย pandas:


กติกาในคาบ

- ไม่ต้องกลัวพิมพ์ผิด แก้ไขได้เสมอ

ภาพรวมหน้าจอ Gemini in Colab

จุดที่ผู้เรียนควรรู้ก่อนเริ่ม

- พื้นที่เขียนโค้ดอยู่ใน Code Cell
- คำสั่งอธิบายงานให้ AI อยู่ใน Text/Prompt
- กดรันทีละเซลล์เพื่อเช็คผลลัพธ์ทันที
- ถ้าผลไม่ถูกต้อง ให้ปรับ prompt แล้วรันใหม่



ตัวอย่างโค้ดอ่านไฟล์ CSV ใน Colab ด้วย AI ช่วยเขียน

```
import pandas as pd
df = pd.read_csv('/content/president_heights.csv')
print(df.head())
```

การใช้ Gemini ใน Colab

1. Predict next word/code

- พิมพ์โค้ดครึ่งหนึ่งแล้วกด Tab เพื่อให้ AI ช่วยเติมโค้ดที่เหลือ
- เหมาะสำหรับโค้ดที่คุ้นเคยแต่ต้องการความรวดเร็ว
- พิมพ์ comment อธิบายสิ่งที่ต้องการ แล้วกด Tab เพื่อให้ AI ช่วยเขียนโค้ด

2. Generate code from prompt

- พิมพ์คำอธิบายงานที่ต้องการ เช่น "ช่วยเขียนโค้ด Python สำหรับอ่านไฟล์ CSV และตรวจสอบ missing values"
- AI จะสร้างโค้ดให้ตามคำอธิบาย และสามารถปรับแต่งได้ตามต้องการ
- เหมาะสำหรับงานที่ไม่คุ้นเคยหรือซับซ้อน

Prompt พื้นฐานที่ใช้กับ AI ใน Colab

Template Prompt

"ช่วยเขียนโค้ด Python สำหรับ [งานที่ต้องการ] โดยใช้ pandas พร้อมอธิบายทีละบรรทัด และให้ตรวจสอบข้อผิดพลาดที่พบบ่อย"

ตัวอย่างงาน

- อ่านไฟล์ CSV และตรวจ missing values
- แปลงชนิดข้อมูลวันที่
- สรุปสถิติเบื้องต้นและกราฟพื้นฐาน

Basic Python + AI Prompting for Data Analysis

Basic Python + AI Prompting

1. Python พื้นฐานสำหรับงานข้อมูล
2. numpy พื้นฐานที่ต้องใช้จริง
3. pandas พื้นฐานที่ต้องใช้จริง

เป้าหมายช่วงนี้

- ให้ผู้เรียน "สั่ง AI ได้งานที่ตรงโจทย์"
- ให้ผู้เรียน "อ่านและตรวจโค้ดได้อย่างมั่นใจ"

Basic Python

- ตัวแปรและชนิดข้อมูล (Variables and Data Types)
 - ได้แก่ชนิดข้อมูลพื้นฐาน เช่น int, float, str, bool
- การรับและแสดงผลข้อมูล (Input and Output)
 - เช่น print(), input(), display()
- การควบคุมการทำงาน (Control Flow)
 - เช่น if-else, for loop, while loop
- การคำนวณทางคณิตศาสตร์เบื้องต้น (Basic Arithmetic Operations)
 - เช่น +, -, *, /, %, **, //, และการใช้ฟังก์ชัน math

Click on icon for lab:  Open in Colab

Control Flow

- คำสั่งเงื่อนไข (Conditional Statements)
 - ได้แก่ if, elif, else
- การวนลูป (Loops)
 - ได้แก่ for, while

Click on icon for lab:  Open in Colab

Functions

- การสร้างฟังก์ชัน (Defining Functions)
 - ใช้ `def` ชื่อฟังก์ชัน(พารามิเตอร์):
 - การเรียกใช้ฟังก์ชัน (Calling Functions)
- การใช้พารามิเตอร์และค่าที่คืนกลับ (Parameters and Return Values)
 - การส่งค่าผ่านพารามิเตอร์
 - การคืนค่าผ่าน `return` statement
- การเขียนโค้ดแบบแยกส่วน (Modular Code)
 - การ save ด้วย `%%writefile` เป็นฟังก์ชันที่ใช้ซ้ำในไฟล์ `.py` แล้ว `import` มาใช้ เช่น `%%writefile calRectang.py`
 - การเรียนรู้การ `import` ฟังก์ชันจากไฟล์ `.py` มาใช้ใน Colab

Click on icon for lab:  Open in Colab

ข้อมูลประเภท List

- การสร้าง List และการเข้าถึงสมาชิก (Creating and Accessing Lists)
 - เช่น `my_list = [1, 2, 3, 4, 5]`
- การเข้าถึงสมาชิกด้วย index เช่น `my_list[0]` จะได้ค่า 1
- การเข้าถึงสมาชิกจากท้าย list เช่น `my_list[-1]` จะได้ค่า 5
- การเข้าถึงสมาชิกแบบ slice เช่น `my_list[1:4]` จะได้ค่า `[2, 3, 4]`
- การใช้ for loop เพื่อวนลูปผ่านสมาชิกของ list เช่น `for item in my_list: print(item)`

Click on icon for lab:  Open in Colab

Numpy พื้นฐานที่ใช้บ่อย

Numpy เป็น library สำหรับการคำนวณเชิงตัวเลขและการจัดการ array ใน Python

ตัวอย่างการใช้

```
import numpy as np

# สร้าง array 1 มิติ
a = np.array([1, 2, 3, 4, 5])

# สร้าง array 2 มิติ
b = np.array([[1, 2, 3], [4, 5, 6]])

# การบวก array
c = np.array([6, 7, 8, 9, 10])
```

```
# การบวก array กับ array
d = b + c # บวกสมาชิกของ b กับ c

# การคูณ array กับ array
e = b * c # คูณสมาชิกของ b กับ c

# การคำนวณสถิติพื้นฐาน
mean_value = np.mean(a) # ค่าเฉลี่ยของ a
max_value = np.max(a) # ค่ามากที่สุดของ a
min_value = np.min(a) # ค่าน้อยที่สุดของ a
```

Pandas พื้นฐานที่ใช้บ่อย

คำสั่งหลัก 6 ตัว

1. `read_csv()` อ่านไฟล์
2. `head()` ดูตัวอย่างข้อมูล
3. `info()` ดูชนิดข้อมูลและ missing
4. `describe()` ดูสถิติพื้นฐาน
5. `isna().sum()` นับ missing values
6. `groupby()` สรุปผลตามกลุ่ม

เป้าหมาย

- ดูโครงสร้างข้อมูลให้เป็นก่อนวิเคราะห์

ตัวอย่าง pandas workflow แบบสั้น

```
import pandas as pd

df = pd.read_csv('/content/president_heights.csv')
print(df.head())
print(df.info())
print(df.describe(include='all'))
print(df.isna().sum())
```

จุดสังเกต

- ถ้าชื่อคอลัมน์ผิด โค้ดจะพังทันที
- ถ้ามี missing มาก ต้องจัดการก่อนสรุปผล

Activity 1 (5 นาที): ให้ AI เขียนโค้ดสำรวจข้อมูลให้เรา

1. ดาวน์โหลดไฟล์ presidents.csv ที่
https://github.com/toche7/DataSets/blob/main/president_heights.csv
2. upload ไฟล์ขึ้น Colab
3. ใช้ prompt ต่อไปนี้ให้ AI ช่วยเขียนโค้ดสำรวจข้อมูลให้เรา

ช่วยเขียนโค้ด Python ใน Google Colab เพื่ออ่านไฟล์ /content/president_heights.csv
จากนั้นแสดงผล head(), info(), describe(), และจำนวน missing values รายคอลัมน์
ให้โค้ดรันได้ทันทีและมีคอมเมนต์สั้นๆ อธิบายแต่ละขั้นตอน

เกณฑ์ผ่านกิจกรรม

- รันได้จริงโดยไม่แก้ไข 2 จุด
- ผู้เรียนอธิบายได้ว่าแต่ละบรรทัดทำอะไร

Workshop 2: เตรียมข้อมูลและสำรวจข้อมูลด้วย AI

เปิด Notebook สำหรับรันบน Colab




GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-02-president-heights-colab.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ใช้ข้อมูล president_heights.csv ที่อัปโหลดใน Colab
2. กำหนดคำถามการวิเคราะห์ 2-3 ข้อ เช่น ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุดของประธานาธิบดี
3. เขียน prompt เพื่อให้ AI เพื่อวิเคราะห์ข้อมูลและตอบคำถามเหล่านั้น
4. เขียน prompt เพื่อให้ AI ช่วยสร้างกราฟแสดงการกระจายความสูงของประธานาธิบดี

ตัวอย่างรูปภาพการกระจายความสูงของประธานาธิบดีที่สร้างด้วย AI



Data Preparation

ชุดข้อมูลที่ใช้ในช่วงนี้ (Data Preparation + Workshop 3)

- ชุดข้อมูล: [data.go.th - traffic-accident](https://data.go.th/traffic-accident)
- ชื่อข้อมูล: ข้อมูลการตรวจสอบสถานที่เกิดเหตุในคดีอุบัติเหตุจราจร
- หน่วยข้อมูล: รายการตรวจสอบสถานที่เกิดเหตุแต่ละรายการ
- มิติที่ใช้วิเคราะห์: จังหวัด, สถานีตำรวจ, วันและเวลา, สภาพถนน, สัญญาณไฟจราจร และพิกัดสถานที่เกิดเหตุ
- ตัวอย่างคอลัมน์ที่ใช้ใน workshop: จังหวัด, สถานีตำรวจ, วันในสัปดาห์, สภาพถนน, สัญญาณไฟจราจร, ละติจูด, ลองจิจูด

เป้าหมาย: เตรียมข้อมูลให้พร้อมสำหรับทำ EDA และสรุปข้อค้นพบเชิงนโยบาย

1) การกำหนดโจทย์การวิเคราะห์ข้อมูล


จาก "ปัญหางาน" สู่ "คำถามข้อมูล"

- ระบุเป้าหมายเชิงนโยบาย/บริการประชาชน
- นิยามตัวชี้วัดที่สะท้อนผลลัพธ์
- กำหนดขอบเขตข้อมูล: เวลา พื้นที่ หน่วยงาน
- เขียนคำถามที่ตอบได้ด้วยข้อมูลเชิงปริมาณ

ตัวอย่างคำถาม

ข้อมูลอุบัติเหตุจราจรระจุกตัวในจังหวัดหรือสภาพถนนแบบใด และมีข้อมูลพิกัดพร้อมใช้วิเคราะห์มากน้อยเพียงใด?

From Policy Problem to Data Question



2) การเตรียมข้อมูลสำหรับการวิเคราะห์

Data Quality Checklist

- Missing values และค่าผิดปกติ: เช่น จังหวัดหรือวันเวลาเกิดเหตุว่าง และค่าพีกัดแปลงเป็นตัวเลขไม่ได้
- ความซ้ำซ้อนของรายการข้อมูล: ตรวจสอบ `_id` หรือรายการที่มีรายละเอียดเหตุการณ์และพีกัดซ้ำกัน
- ความสอดคล้องของหน่วยและหมวดหมู่: เช่น ชื่อจังหวัด สภาพถนน หรือสัญญาณไฟสะกดไม่ตรงกัน
- ค่าผิดปกติที่ควรตรวจสอบเพิ่มเติม: เช่น ละติจูดอยู่นอกช่วง -90 ถึง 90 หรือลองจิจูดอยู่นอกช่วง -180 ถึง 180

2) การเตรียมข้อมูลสำหรับการวิเคราะห์ (ต่อ)

Data Preparation

- แปลงชนิดข้อมูลให้เหมาะสม: เช่น แปลงวันเวลา ละติจูด และลองจิจูดเป็นชนิดข้อมูลที่ใช้งานได้
- ลบรายการซ้ำโดยใช้ `_id` หรือคีย์ที่เหมาะสมกับรายละเอียดเหตุการณ์
- ทำมาตรฐานค่าหมวดหมู่: ตัดช่องว่างและรวมรูปแบบการเขียนจังหวัด สภาพถนน และสัญญาณไฟ
- ตรวจสอบและจัดการพิกัดที่อยู่นอกช่วง รวมถึงแยกแถวที่ไม่มีพิกัดไว้พิจารณาต่างหาก
- จัดตารางให้อยู่ในรูปแบบ tidy data: ให้ 1 แถว = 1 รายการตรวจสอบสถานที่เกิดเหตุ และ 1 คอลัมน์ = 1 ตัวแปร

ตัวอย่าง Prompt สำหรับ Data Preparation

missing values และค่าผิดปกติ

ช่วยเขียนโค้ด Python ใน Colab เพื่อตรวจสอบ missing values และชนิดข้อมูล
ของชุดข้อมูลการตรวจสถานที่เกิดเหตุในคดีอุบัติเหตุจราจรจาก data.go.th
โดยเน้นคอลัมน์จังหวัด วันเวลาเกิดเหตุ ละติจูด และลองจิจูด
พร้อมแปลงคอลัมน์วันเวลาและพิกัดให้ใช้งานได้ และอธิบายโค้ดที่ละบรรทัด

ความซ้ำซ้อนของรายการข้อมูล

ช่วยเขียนโค้ด Python เพื่อตรวจสอบรายการซ้ำในชุดข้อมูลอุบัติเหตุจราจร
โดยตรวจ `\_id` และรายละเอียดจังหวัด สถานที่ตำรวจ วันเวลาเกิดเหตุ และพิกัด
จากนั้นลบข้อมูลซ้ำโดยเก็บรายการแรก พร้อมอธิบายโค้ดที่ละบรรทัด

Data Preparation Checklist

รายการตรวจสอบและจัดการข้อมูลเบื้องต้นที่ควรทำก่อนวิเคราะห์

1. ตรวจสอบ missing values และค่าผิดปกติ
2. ตรวจสอบความซ้ำซ้อนของรายการข้อมูล
3. ตรวจสอบความสอดคล้องของหน่วยและรหัสข้อมูล
4. ตรวจสอบ outliers และจัดการตามความเหมาะสม
5. แปลงชนิดข้อมูลให้เหมาะสม
6. สร้างคอลัมน์ใหม่เพื่อการวิเคราะห์
7. จัดตารางให้อยู่ในรูปแบบ tidy data

Workshop 3 — Data Preparation Pipeline

เปิด Notebook สำหรับรันบน Colab  [Open in Colab](#)

GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/Workshop3v1.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ใช้ข้อมูลจาก <https://data.go.th/dataset/traffic-accident> และโหลด resource เข้า Colab
2. ตรวจสอบ missing values, duplicates, data types และความสอดคล้องของหมวดหมู่
3. ทำความสะอาดข้อมูล: แปลงวันเวลาและพิกัด ลบรายการซ้ำ และจัดมาตรฐานค่าหมวดหมู่
4. ตรวจสอบพิกัดให้ละติจูดอยู่ในช่วง -90 ถึง 90 และลองจิจูดอยู่ในช่วง -180 ถึง 180
5. สร้างไฟล์ tidy ที่พร้อมทำ EDA ต่อ (เช่น `workshop3_traffic_accident_clean.csv`)

Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA)

ข้อมูลที่ใช้ใน Workshop 5: NSO Population Dataset

ฟิลด์	ชนิด	ตัวอย่างค่า	ความหมาย
year	numeric	2533 , 2543 , 2553	ปีพุทธศักราช
region	text	ทั่วประเทศ , กลาง	ภาค
province	text	รวม , กรุงเทพมหานคร	จังหวัด
area	text	รวม , ในเขตเทศบาล	ประเภทพื้นที่
sex	text	รวม , ชาย , หญิง	เพศ
age_group	text	รวม , 0-4	กลุ่มอายุ
value	numeric	54548530	จำนวนประชากร (คน)

ตัวอย่าง Prompt สำหรับ EDA

EDA เบื้องต้น

ช่วยเขียนโค้ด Python ใน Colab เพื่อทำ EDA ข้อมูลประชากรจากสำนักงานสถิติแห่งชาติ (NSO) โดยใช้คอลัมน์ `year`, `region`, `province`, `area`, `sex`, `age_group` และ `value` ให้แสดงผลขนาดข้อมูล, `info()`, `describe()`, missing values และสร้าง histogram ของ `value` พร้อมอธิบายโค้ดที่ละบรรทัด

ความสัมพันธ์เบื้องต้น

ช่วยเขียนโค้ด Python เพื่อวิเคราะห์ความสัมพันธ์เบื้องต้นของข้อมูลประชากรจาก NSO โดยคำนวณผลรวม `value` แยกตาม `sex` และ `age_group` และเปรียบเทียบระหว่าง `region` หรือ `province` จากนั้นสร้างกราฟเปรียบเทียบ (barplot) และอธิบายว่ากลุ่มใดมีจำนวนประชากรสูง/ต่ำ พร้อมอธิบายโค้ดที่ละบรรทัด

Workshop 5 — Population Statistics Pipeline

โจทย์: EDA ข้อมูลประชากร Dataset: ข้อมูลประชากรจากสำนักงานสถิติแห่งชาติ (NSO)

เปิด Notebook สำหรับรันบน Colab  [Open in Colab](#)

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000

1. ดึงข้อมูลประชากรรายจังหวัดจาก NSO Open Data API
2. ตรวจสอบคุณภาพข้อมูลและจัดรูปแบบให้เหมาะสม
3. ทำความเข้าใจข้อมูลและกำหนดคำถามเพื่อการวิเคราะห์
4. ทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ
5. วิเคราะห์ตามคำถามที่กำหนดและสรุป Insight ที่ได้จากข้อมูล

Hint: Get Data with Colab + AI

Prompt ตัวอย่างสำหรับดึงข้อมูลจาก NSO API

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้
`https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000`
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

link สำรอง กรณี url ด้านบนมีปัญหา:

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้
`https://raw.githubusercontent.com/toche7/DataSets/refs/heads/main/nso_population.csv`
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

Homework — Household Finance Analysis Pipeline

โจทย์: วิเคราะห์ฐานะทางการเงินครัวเรือนไทยจาก NSO Open Data

	Dataset	resource_id
ชุดที่ 1	ค่าใช้จ่ายเฉลี่ยต่อเดือนของครัวเรือน จำแนกตามประเภทค่าใช้จ่าย	697c9b29-d937-4c4e-9d9f-122ff085488b
ชุดที่ 2	หนี้สินเฉลี่ยต่อครัวเรือน จำแนกตามวัตถุประสงค์การกู้ยืม	89cc71ae-f596-4307-b38f-10d61d084801

ความต้องการ:

- 1. ดึงข้อมูลจาก 2 ชุดนี้มาใน Colab ด้วย AI ช่วยเขียนโค้ด
- 2. คำนวณ **สัดส่วนหนี้สิน/ค่าใช้จ่าย** จำแนกตามสถานะทางเศรษฐกิจสังคม
- 3. หาจังหวัดที่มีภาระหนี้สูงสุด / ต่ำสุด
- 4. สร้าง Summary Report ส่ง Email อัตโนมัติ

โครงสร้างข้อมูล: ชุดที่ 1 — ค่าใช้จ่ายครัวเรือน

ฟิลด์	ชนิด	ตัวอย่างค่า
year	text	"2566"
province	text	"กรุงเทพมหานคร" , "เชียงใหม่"
soc_eco_class1	text	"ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..."
soc_eco_class2	text	รายละเอียดสถานะ เช่น "ผู้จัดการนักวิชาการ..."
type_expenditure1	text	"ค่าใช้จ่ายเพื่อการอุปโภคบริโภค" / "ค่าใช้จ่ายทั้งสิ้นต่อเดือน"
type_expenditure2	text	"อาหารและเครื่องดื่ม" , "ที่อยู่อาศัย..." , "การศึกษา"
value	numeric	21740.00 (บาท/เดือน)

โครงสร้างข้อมูล: ชุดที่ 2 — หนี้สินครัวเรือน

ฟิลด์	ชนิด	ตัวอย่างค่า
year	text	"2566"
province	text	"กรุงเทพมหานคร" , "สมุทรปราการ"
soc_eco_class1	text	"ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..."
soc_eco_class2	text	รายละเอียดสถานะ เช่น "คนงานด้านการขนส่ง..."
hhdebt_totaldebt	text	"จำนวนครัวเรือนทั้งสิ้น" / "จำนวนหนี้สินเฉลี่ยต่อครัวเรือน"
purpose_source_bor	text	"จำนวนหนี้สินเฉลี่ยต่อครัวเรือน" / "ใช้ซื้อ/เช่าซื้อบ้าน..." / "หนี้ในระบบ"
value	numeric	300000.00 (บาท) หรือ จำนวนครัวเรือน
unit	text	"บาท" หรือ "ครัวเรือน"

Hint: Get Data with Colab + AI

prompt

```
ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้  
https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=  
697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000  
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย
```

คำใช้ง่ายคร่าวๆ

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000

ห้สืครว้

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=89cc71ae-f596-4307-b38f-10d61d084801&limit=5000

าวโหลดผ่าน browser

หาก url ด้านบนมีปัญหาสามารถใช้ เปิดจาก browser แล้วดาวน์โหลดเป็นไฟล์ CSV/JSON จากนั้นอัปโหลดขึ้น Colab ได้เช่นกัน

สรุปขั้นตอนการวิเคราะห์ข้อมูลด้วย AI ใน Colab

1. กำหนดคำถามการวิเคราะห์ที่ชัดเจน
2. ดึงข้อมูลจากแหล่งที่มา (เช่น NSO API) ด้วย AI ช่วยเขียนโค้ด
3. ตรวจสอบและเตรียมข้อมูลให้พร้อมสำหรับการวิเคราะห์
4. ทำ EDA เพื่อเข้าใจข้อมูลและค้นหา Insight เบื้องต้น
5. สรุปผลลัพธ์และเตรียมข้อมูลสำหรับการนำเสนอในขั้นตอนถัดไป

คำศัพท์ที่ควรรู้เพื่อการเขียน prompt ด้านการวิเคราะห์ข้อมูล

จัดเป็นหมวดตาม workflow เพื่อเลือกใช้ prompt ได้ง่ายขึ้น

1. ตอนโหลดข้อมูล
2. ตอน clean ข้อมูล
3. ตอนสร้างกราฟ
4. ตอนสรุปผล

คำศัพท์ที่ควรรู้: ตอนโหลดข้อมูล

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
DataFrame	โครงสร้างข้อมูลใน Python ที่ใช้เก็บข้อมูลในรูปแบบตาราง	"ช่วยเขียนโค้ด Python ดึงข้อมูลจาก API มาเก็บใน DataFrame ชื่อ df"
API (Application Programming Interface)	ชุดของคำสั่งและโปรโตคอลที่ใช้ในการเข้าถึงและสื่อสารกับบริการหรือแหล่งข้อมูล	"ช่วยเขียนโค้ด Python ดึงข้อมูลจาก NSO API มาเก็บใน DataFrame ชื่อ df"

คำศัพท์ที่ควรรู้: ตอน clean ข้อมูล

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Missing values	ค่าที่ขาดหายไปข้อมูล	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ missing values ในคอลัมน์ <code>age</code> "
Outliers	ค่าที่ผิดปกติที่อาจเกิดจากข้อผิดพลาดหรือเหตุการณ์พิเศษ	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ outliers ในคอลัมน์ <code>waiting_time</code> "
Data standardization	การปรับสเกลข้อมูลให้อยู่ในมาตรฐานเดียวกัน (เช่น ค่าเฉลี่ยเป็น 0 และส่วนเบี่ยงเบนมาตรฐานเป็น 1)	"ช่วยเขียนโค้ด Python เพื่อทำ standardization ให้คอลัมน์ <code>age</code> และ <code>income</code> ด้วยวิธี z-score และเปรียบเทียบก่อน-หลังการแปลง"
Uniqueness	การตรวจสอบว่าค่าในคอลัมน์ซ้ำกันมากน้อยเพียงใด	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบ uniqueness ของทุกคอลัมน์ด้วย <code>nunique()</code> และสรุปผลเป็นตาราง"
Unique values	ค่าที่ไม่ซ้ำกันในแต่ละคอลัมน์	"ช่วยเขียนโค้ด Python เพื่อแสดง unique values ของคอลัมน์ <code>region</code> และ <code>area</code> พร้อมจำนวนค่า"

คำศัพท์ที่ควรรู้: ตอน clean ข้อมูล

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Cardinality	จำนวนค่าที่แตกต่างกันในคอลัมน์หนึ่งๆ	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบ cardinality ของทุกคอลัมน์ และระบุคอลัมน์ที่มี cardinality สูงผิดปกติ"
Tidy data	รูปแบบข้อมูลที่มีโครงสร้างชัดเจน โดยมี 1 ตัวแปรต่อ 1 คอลัมน์ และ 1 แถวต่อ 1 รายการ	"ช่วยเขียนโค้ด Python เพื่อจัดตารางข้อมูลให้อยู่ในรูปแบบ tidy data"

คำศัพท์ที่ควรรู้: ตอนสร้างกราฟ

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Visualization	การสร้างภาพกราฟิกเพื่อสื่อสารข้อมูลและผลลัพธ์จากการวิเคราะห์	"ช่วยเขียนโค้ด Python เพื่อสร้างกราฟ histogram ของเวลารอคิว"
Boxplot	กราฟที่ใช้ดูการกระจายของข้อมูล ค่ามัธยฐาน และค่าพิດปกติ	"ช่วยเขียนโค้ด Python เพื่อสร้าง boxplot ของคอลัมน์ <code>value</code> แยกตาม <code>region</code> "
Scatter plot	กราฟจุดที่ใช้ดูความสัมพันธ์ระหว่างตัวแปรเชิงตัวเลขสองตัว	"ช่วยเขียนโค้ด Python เพื่อสร้าง scatter plot ระหว่าง <code>age</code> และ <code>waiting_time</code> พร้อมเส้นแนวโน้ม"
Histogram	กราฟแท่งแสดงการกระจายความถี่ของค่าตัวแปรเชิงตัวเลข	"ช่วยเขียนโค้ด Python เพื่อสร้าง histogram ของคอลัมน์ <code>value</code> และอธิบายการกระจายข้อมูล"
Bar chart	กราฟแท่งเปรียบเทียบค่าระหว่างหมวดหมู่	"ช่วยเขียนโค้ด Python เพื่อสร้าง bar chart เปรียบเทียบค่าเฉลี่ย <code>value</code> ตาม <code>level_of_edu</code> "

คำศัพท์ที่ควรรู้: ตอนสรุปผล

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Correlation	ความสัมพันธ์ระหว่างตัวแปรสองตัว	"ช่วยเขียนโค้ด Python เพื่อคำนวณค่า correlation ระหว่างเวลารอคิวและอายุ"
EDA (Exploratory Data Analysis)	กระบวนการสำรวจและวิเคราะห์ข้อมูลเบื้องต้นเพื่อเข้าใจโครงสร้างและแนวโน้มของข้อมูล	"ช่วยเขียนโค้ด Python เพื่อทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ"
Summary Report	รายงานสรุปผลลัพท์จากการวิเคราะห์ข้อมูล	"ช่วยเขียนโค้ด Python เพื่อสร้าง Summary Report จากผลการวิเคราะห์และส่ง Email อัตโนมัติ"

สรุป Session 02

- เริ่มจากโจทย์ที่ชัด ก่อนลงมือกับเครื่องมือ
- คุณภาพข้อมูลกำหนดคุณภาพของ Insight
- ใช้ AI เป็นผู้ช่วยคิดและเร่งงาน แต่ต้องมีการตรวจสอบ
- EDA ที่ดีคือฐานสำคัญของการทำ visualization และรายงาน

Q&A

เตรียมต่อ Session 03: Data Visualization with Gemini

วิทยากร

ผศ.ดร.ทวิศักดิ์ สมานชื่น

Asst. Prof. Taweesak Samanchuen, Ph.D.

- รองผู้อำนวยการฝ่ายดิจิทัลเทคโนโลยี **MULKC**
- อาจารย์ประจำสาขา **ITM** คณะวิศวกรรมศาสตร์ มหาวิทยาลัยมหิดล
- หัวหน้าโครงการ **CBTU**

 [Profile](#)

 t.samanchuen@gmail.com

 081-441-4906

website: cbtumu.net | facebook: [cbtumu](https://www.facebook.com/cbtumu)

ขอบคุณครับ

ผศ.ดร.ทวีศักดิ์ สمانชื่น