



Session 02

การสำรวจและวิเคราะห์ข้อมูลด้วย Generative AI และ Google Colab

Stat on Campus: Data innovators

Turning data into impact for public sector

Asst. Prof. Taweesak Samanchuen, Ph.D.

Mahidol University

วัตถุประสงค์ของ Session

เมื่อจบช่วงนี้ ผู้เข้าอบรมสามารถ:

1. เริ่มใช้งาน Google Colab ได้ แม้ไม่เคยใช้งานมาก่อน
2. เข้าใจบทบาทของ AI ภายใน workflow การวิเคราะห์ข้อมูลใน Colab
3. แปลงโจทย์เชิงนโยบายเป็นคำถามเชิงข้อมูลได้
4. ตรวจสอบและเตรียมข้อมูลก่อนวิเคราะห์ได้เป็นระบบ
5. ใช้ Generative AI ช่วยสำรวจข้อมูลเบื้องต้นได้

สารบัญ

1. Colab สำหรับผู้เริ่มต้น
2. Basic Python + AI Prompting for Data Analysis
3. Data Preparation & Quality Check
4. Exploratory Data Analysis (EDA)
5. Workshop Pipeline Series
 - Workshop 2: Titanic Quick Start
 - Workshop 3: Data Preparation Pipeline
 - Workshop 4: EDA Pipeline
 - Workshop 5: Population Statistics (NSO)
 - Workshop 6: Household Finance (NSO)

สร้างภาพด้วย Gemini

Prompt

สร้างภาพ super hero ของตัวฉันเองในสไตล์การ์ตูนญี่ปุ่น พร้อมฉากหลังเป็นเมืองใหญ่ในยามค่ำคืน และใส่ข้อความ "AI Data Hero" ที่ด้านล่างของภาพ

- เขียน prompt ตามตัวอย่างนี้
- แบนรูปภาพของคุณเองเพื่อให้ AI สร้างภาพ super hero ที่มีลักษณะคล้ายคุณ

ทดลองวิเคราะห์ข้อมูลด้วย Gemini

1. ดาวน์โหลดไฟล์ presidents.csv ที่
https://github.com/toche7/DataSets/blob/main/president_heights.csv
2. เปิดใช้งาน gemini.google.com
3. เปิด chat ใหม่และ add ไฟล์ president_heights.csv ที่ดาวน์โหลดจาก GitHub
4. พิมพ์ prompt เช่น

ช่วยวิเคราะห์ข้อมูลความสูงของประธานาธิบดีในไฟล์นี้ และตอบคำถามต่อไปนี้: ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุด พร้อมสร้างกราฟการกระจายความสูงด้วย

เปรียบเทียบที่ได้จาก Super Hero กับภาพ Histogram

- ภาพ super hero เป็นผลลัพธ์จากการใช้ AI สร้างภาพตามคำอธิบายที่ให้ไป ซึ่งเป็นการสร้างสรรค์ที่ไม่จำกัดและมีความยืดหยุ่นสูง
- ภาพ Histogram เป็นการแสดงข้อมูลเชิงสถิติที่แสดงการกระจายของข้อมูล ซึ่งมีความแม่นยำและเป็นทางการมากกว่า
- ทั้งสองภาพมีจุดประสงค์และการใช้งานที่แตกต่างกัน โดยภาพ super hero เน้นความสร้างสรรค์และการสื่อสารที่น่าสนใจ ในขณะที่ Histogram เน้นการวิเคราะห์ข้อมูลและการสื่อสารข้อมูลเชิงปริมาณอย่างชัดเจน

ใช้เทคโนโลยีที่ต่างกันคือ

- ภาพ super hero ใช้ Generative AI (model: nano-Banana) ในการสร้างสรรค์ภาพตามคำอธิบายที่ให้ไป
- ภาพ Histogram ใช้เทคนิคการวิเคราะห์ข้อมูลและการสร้างกราฟจากข้อมูลที่มีอยู่แล้ว โดยอาจใช้เครื่องมือเช่น Python, R หรือซอฟต์แวร์วิเคราะห์ข้อมูลอื่น ๆ ในการสร้างกราฟนี้

Colab สำหรับผู้เริ่มต้น

Colab คืออะไร ทำไมต้องใช้ Colab ในการวิเคราะห์ข้อมูลด้วย AI

Colab คืออะไร

- แพลตฟอร์มโน้ตบุ๊กออนไลน์ที่ Google ให้บริการฟรี
- รองรับการเขียนโค้ด Python และการใช้ AI ช่วยเขียนโค้ดได้ในทีเดียว
- เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความยืดหยุ่นและตรวจสอบได้

สิ่งที่ผู้เรียนส่วนใหญ่กังวล

- ไม่เคยเขียนโค้ดมาก่อน
- ไม่แน่ใจว่าจะเริ่มจากปุ่มไหน
- กลัวพิมพ์ผิดแล้วใช้งานต่อไม่ได้



ทำไม Session นี้ต้องใช้ Colab (ไม่ใช่ AI Chat โดยตรง)

เหตุผลหลัก

1. **ทำงานวิเคราะห์ได้จริง:** Colab ช่วยให้เราทำงานกับข้อมูลจริงได้ ตั้งแต่การโหลดข้อมูล, ทำความสะอาด, วิเคราะห์ และสร้างกราฟในที่เดียว
2. **ตรวจสอบได้:** ทุกขั้นตอนการวิเคราะห์ถูกบันทึกใน Notebook เดียว ทำให้สามารถตรวจสอบย้อนกลับและทำซ้ำได้ง่าย
3. **เรียนรู้การใช้ AI ใน workflow จริง:** การใช้ AI ช่วยเขียนโค้ดใน Colab เป็นทักษะที่สำคัญในการทำงานวิเคราะห์ข้อมูลยุคใหม่ ซึ่งไม่สามารถเรียนรู้ได้จากการใช้ AI Chat อย่างเดียว

สรุป

AI Chat อย่างเดียว "ตอบได้เร็ว" แต่ Colab + AI "ทำงานวิเคราะห์ได้จริงและตรวจสอบได้"

เปรียบเทียบ: AI Chat โดยตรง vs Colab + AI

ประเด็น	AI Chat โดยตรง	Colab + AI
การเก็บขั้นตอน	กระจัดกระจายตามบทสนทนา	อยู่ใน Notebook เดียว
การทำซ้ำผลลัพธ์	ทำได้ยาก	ทำได้ง่าย (Run all)
การตรวจสอบย้อนกลับ	จำกัด	ชัดเจนและตรวจสอบได้
ความพร้อมใช้งานหน้างาน	ปานกลาง	สูง

สรุป: Colab + AI เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความถูกต้องและตรวจสอบได้ ในขณะที่ AI Chat เหมาะสำหรับการตอบคำถามหรือสร้างโค้ดอย่างรวดเร็วในขั้นตอนแรก

Workshop 1: Quick Start Colab (สำหรับผู้เริ่มต้น)

5 ขั้นตอนแรกที่ต้องทำ

1. ไปที่ <https://colab.research.google.com/> และเลือก "New Notebook"
2. ตั้งชื่อไฟล์ให้สื่อความหมายของโจทย์
3. ทดลองใช้งาน Code Cell: เช่น `x = 10; y = 20; print(x + y)`
4. ทดลองใช้งาน Text Cell: เขียนคำอธิบายสั้นๆ ว่า "นี่คือการทดสอบ Text Cell"
5. ทดลอง upload ข้อมูล : presidents.csv จากเครื่องขึ้น Colab (ไอคอนโฟลเดอร์ > Upload)
https://github.com/toche7/DataSets/blob/main/president_heights.csv
6. รันโค้ดอ่านไฟล์ด้วย pandas:


กติกาในคาบ

- ไม่ต้องกลัวพิมพ์ผิด แก้ไขได้เสมอ

ภาพรวมหน้าจอ Gemini in Colab

จุดที่ผู้เรียนควรรู้ก่อนเริ่ม

- พื้นที่เขียนโค้ดอยู่ใน Code Cell
- คำสั่งอธิบายงานให้ AI อยู่ใน Text/Prompt
- กดรันทีละเซลล์เพื่อเช็คผลลัพธ์ทันที
- ถ้าผลไม่ถูกต้อง ให้ปรับ prompt แล้วรันใหม่



ตัวอย่างโค้ดอ่านไฟล์ CSV ใน Colab ด้วย AI ช่วยเขียน

```
import pandas as pd
df = pd.read_csv('/content/president_heights.csv')
print(df.head())
```

การใช้ Gemini ใน Colab

1. Predict next word/code

- พิมพ์โค้ดครึ่งหนึ่งแล้วกด Tab เพื่อให้ AI ช่วยเติมโค้ดที่เหลือ
- เหมาะสำหรับโค้ดที่คุ้นเคยแต่ต้องการความรวดเร็ว
- พิมพ์ comment อธิบายสิ่งที่ต้องการ แล้วกด Tab เพื่อให้ AI ช่วยเขียนโค้ด

2. Generate code from prompt

- พิมพ์คำอธิบายงานที่ต้องการ เช่น "ช่วยเขียนโค้ด Python สำหรับอ่านไฟล์ CSV และตรวจสอบ missing values"
- AI จะสร้างโค้ดให้ตามคำอธิบาย และสามารถปรับแต่งได้ตามต้องการ
- เหมาะสำหรับงานที่ไม่คุ้นเคยหรือซับซ้อน

Prompt พื้นฐานที่ใช้กับ AI ใน Colab

Template Prompt

"ช่วยเขียนโค้ด Python สำหรับ [งานที่ต้องการ] โดยใช้ pandas พร้อมอธิบายทีละบรรทัด และให้ตรวจสอบข้อผิดพลาดที่พบบ่อย"

ตัวอย่างงาน

- อ่านไฟล์ CSV และตรวจ missing values
- แปลงชนิดข้อมูลวันที่
- สรุปสถิติเบื้องต้นและกราฟพื้นฐาน

Basic Python + AI Prompting for Data Analysis

Basic Python + AI Prompting

1. Python พื้นฐานสำหรับงานข้อมูล
2. numpy พื้นฐานที่ต้องใช้จริง
3. pandas พื้นฐานที่ต้องใช้จริง

เป้าหมายช่วงนี้

- ให้ผู้เรียน "สั่ง AI ได้งานที่ตรงโจทย์"
- ให้ผู้เรียน "อ่านและตรวจโค้ดได้อย่างมั่นใจ"

Basic Python

- ตัวแปรและชนิดข้อมูล (Variables and Data Types)
 - ได้แก่ชนิดข้อมูลพื้นฐาน เช่น int, float, str, bool
- การรับและแสดงผลข้อมูล (Input and Output)
 - เช่น print(), input(), display()
- การควบคุมการทำงาน (Control Flow)
 - เช่น if-else, for loop, while loop
- การคำนวณทางคณิตศาสตร์เบื้องต้น (Basic Arithmetic Operations)
 - เช่น +, -, *, /, %, **, //, และการใช้ฟังก์ชัน math

Click on icon for lab:  Open in Colab

Control Flow

- คำสั่งเงื่อนไข (Conditional Statements)
 - ได้แก่ if, elif, else
- การวนลูป (Loops)
 - ได้แก่ for, while

Click on icon for lab:  Open in Colab

Functions

- การสร้างฟังก์ชัน (Defining Functions)
 - ใช้ `def` ชื่อฟังก์ชัน(พารามิเตอร์):
 - การเรียกใช้ฟังก์ชัน (Calling Functions)
- การใช้พารามิเตอร์และค่าที่คืนกลับ (Parameters and Return Values)
 - การส่งค่าผ่านพารามิเตอร์
 - การคืนค่าผ่าน `return` statement
- การเขียนโค้ดแบบแยกส่วน (Modular Code)
 - การ save ด้วย `%%writefile` เป็นฟังก์ชันที่ใช้ซ้ำในไฟล์ `.py` แล้ว `import` มาใช้ เช่น `%%writefile calRectang.py`
 - การเรียนรู้การ `import` ฟังก์ชันจากไฟล์ `.py` มาใช้ใน Colab

Click on icon for lab:  [Open in Colab](#)

ข้อมูลประเภท List

- การสร้าง List และการเข้าถึงสมาชิก (Creating and Accessing Lists)
 - เช่น `my_list = [1, 2, 3, 4, 5]`
- การเข้าถึงสมาชิกด้วย index เช่น `my_list[0]` จะได้ค่า 1
- การเข้าถึงสมาชิกจากท้าย list เช่น `my_list[-1]` จะได้ค่า 5
- การเข้าถึงสมาชิกแบบ slice เช่น `my_list[1:4]` จะได้ค่า `[2, 3, 4]`
- การใช้ for loop เพื่อวนลูปผ่านสมาชิกของ list เช่น `for item in my_list: print(item)`

Click on icon for lab:  Open in Colab

Numpy พื้นฐานที่ใช้บ่อย

Numpy เป็น library สำหรับการคำนวณเชิงตัวเลขและการจัดการ array ใน Python

ตัวอย่างการใช้

```
import numpy as np

# สร้าง array 1 มิติ
a = np.array([1, 2, 3, 4, 5])

# สร้าง array 2 มิติ
b = np.array([[1, 2, 3], [4, 5, 6]])

# การบวก array
c = np.array([6, 7, 8, 9, 10])
```

```
# การบวก array กับ array
d = b + c # บวกสมาชิกของ b กับ c

# การคูณ array กับ array
e = b * c # คูณสมาชิกของ b กับ c

# การคำนวณสถิติพื้นฐาน
mean_value = np.mean(a) # ค่าเฉลี่ยของ a
max_value = np.max(a) # ค่ามากที่สุดของ a
min_value = np.min(a) # ค่าน้อยที่สุดของ a
```

Pandas พื้นฐานที่ใช้บ่อย

คำสั่งหลัก 6 ตัว

1. `read_csv()` อ่านไฟล์
2. `head()` ดูตัวอย่างข้อมูล
3. `info()` ดูชนิดข้อมูลและ missing
4. `describe()` ดูสถิติพื้นฐาน
5. `isna().sum()` นับ missing values
6. `groupby()` สรุปผลตามกลุ่ม

เป้าหมาย

- ดูโครงสร้างข้อมูลให้เป็นก่อนวิเคราะห์

ตัวอย่าง pandas workflow แบบสั้น

```
import pandas as pd

df = pd.read_csv('/content/president_heights.csv')
print(df.head())
print(df.info())
print(df.describe(include='all'))
print(df.isna().sum())
```

จุดสังเกต

- ถ้าชื่อคอลัมน์ผิด โค้ดจะพังทันที
- ถ้ามี missing มาก ต้องจัดการก่อนสรุปผล

Activity 1 (5 นาที): ให้ AI เขียนโค้ดสำรวจข้อมูลให้เรา

1. ดาวน์โหลดไฟล์ presidents.csv ที่
https://github.com/toche7/DataSets/blob/main/president_heights.csv
2. upload ไฟล์ขึ้น Colab
3. ใช้ prompt ต่อไปนี้ให้ AI ช่วยเขียนโค้ดสำรวจข้อมูลให้เรา

ช่วยเขียนโค้ด Python ใน Google Colab เพื่ออ่านไฟล์ /content/president_heights.csv
จากนั้นแสดงผล head(), info(), describe(), และจำนวน missing values รายคอลัมน์
ให้โค้ดรันได้ทันทีและมีคอมเมนต์สั้นๆ อธิบายแต่ละขั้นตอน

เกณฑ์ผ่านกิจกรรม

- รับได้จริงโดยไม่แก้ไข 2 จุด
- ผู้เรียนอธิบายได้ว่าแต่ละบรรทัดทำอะไร

Workshop 2: เตรียมข้อมูลและสำรวจข้อมูลด้วย AI

เปิด Notebook สำหรับรันบน Colab




GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-02-president-heights-colab.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ใช้ข้อมูล president_heights.csv ที่อัปโหลดใน Colab
2. กำหนดคำถามการวิเคราะห์ 2-3 ข้อ เช่น ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุดของประธานาธิบดี
3. เขียน prompt เพื่อให้ AI เพื่อวิเคราะห์ข้อมูลและตอบคำถามเหล่านั้น
4. เขียน prompt เพื่อให้ AI ช่วยสร้างกราฟแสดงการกระจายความสูงของประธานาธิบดี

ตัวอย่างรูปกราฟการกระจายความสูงของประธานาธิบดีที่สร้างด้วย AI



Data Preparation

1) การกำหนดโจทย์การวิเคราะห์ข้อมูล


จาก "ปัญหางาน" สู่ "คำถามข้อมูล"

- ระบุเป้าหมายเชิงนโยบาย/บริการประชาชน
- นิยามตัวชี้วัดที่สะท้อนผลลัพธ์
- กำหนดขอบเขตข้อมูล: เวลา พื้นที่ หน่วยงาน
- เขียนคำถามที่ตอบได้ด้วยข้อมูลเชิงปริมาณ

ตัวอย่างคำถาม

ปัจจัยใดสัมพันธ์กับความล่าช้าในการให้บริการมากที่สุด?

From Policy Problem to Data Question



2) การเตรียมข้อมูลสำหรับการวิเคราะห์

Data Quality Checklist

- Missing values และค่าผิดปกติรูปแบบ: เช่น คอลัมน์อายุว่าง, วันที่บันทึกเป็นทั้ง 2026-01-05 และ 05/01/2026
- ความซ้ำซ้อนของรายการข้อมูล: เช่น เลขคำขอเดียวกันถูกบันทึกซ้ำ 2 แถว ทำให้ยอดนับสูงเกินจริง
- ความสอดคล้องของหน่วยและรหัสข้อมูล: เช่น จบประมาณบางแถวเป็นบาท บางแถวเป็นพันบาท หรือรหัสจังหวัด 10 ปนกับ BKK
- Outliers ที่ควรตรวจสอบเพิ่มเติม: เช่น เวลารอคิว 1,200 นาที อาจเป็นค่าพิมพ์ผิดหรือเหตุการณ์พิเศษที่ต้องแยกวิเคราะห์

2) การเตรียมข้อมูลสำหรับการวิเคราะห์ (ต่อ)

Data Preparation

- แปลงชนิดข้อมูลให้เหมาะสม: เช่น แปลงคอลัมน์ `service_date` จากข้อความเป็นชนิดวันที่ และแปลง `waiting_time` เป็นตัวเลข
- สร้างคอลัมน์ใหม่เพื่อการวิเคราะห์: เช่น คำนวณ `waiting_time_min` และสร้าง `is_weekend` เพื่อดูผลต่างวันทำการ/วันหยุด
- จัดตารางให้อยู่ในรูปแบบ tidy data: เช่น แยกคอลัมน์ที่รวมหลายค่าให้เหลือ 1 ตัวแปรต่อ 1 คอลัมน์ และ 1 แถวต่อ 1 รายการบริการ

ตัวอย่าง Prompt สำหรับ Data Preparation

missing values และค่าผิดปกติ

ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ missing values ในคอลัมน์ `age` และแปลงคอลัมน์ `service\_date` ให้เป็นชนิดวันที่ในรูปแบบ YYYY-MM-DD พร้อมอธิบายโค้ดที่ละบรรทัด

ความซ้ำซ้อนของรายการข้อมูล

ช่วยเขียนโค้ด Python เพื่อตรวจสอบและลบแถวที่มีเลขค่าซ้ำกันในคอลัมน์ `request\_id` พร้อมอธิบายโค้ดที่ละบรรทัด"

Data Preparation Checklist

รายการตรวจสอบและจัดการข้อมูลเบื้องต้นที่ควรทำก่อนวิเคราะห์

1. ตรวจสอบ missing values และค่าผิดปกติ
2. ตรวจสอบความซ้ำซ้อนของรายการข้อมูล
3. ตรวจสอบความสอดคล้องของหน่วยและรหัสข้อมูล
4. ตรวจสอบ outliers และจัดการตามความเหมาะสม
5. แปลงชนิดข้อมูลให้เหมาะสม
6. สร้างคอลัมน์ใหม่เพื่อการวิเคราะห์
7. จัดตารางให้อยู่ในรูปแบบ tidy data

Workshop 3 — Data Preparation Pipeline

เปิด Notebook สำหรับรันบน Colab



GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-03-data-preparation-pipeline.ipynb>

กิจกรรมฝึกปฏิบัติ

1. โหลด Titanic dataset (seaborn หรือ fallback CSV)
2. ตรวจสอบ missing values, duplicates, และ data types
3. ทำความสะอาดข้อมูล (เติมค่า `age`, `embarked`, `fare`)
4. ตรวจสอบ outlier ของ `fare` และสร้าง tidy summary (`survival_rate`)
5. export ไฟล์ผลลัพธ์สำหรับ EDA ต่อ

Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA)

สิ่งที่ต้องตอบให้ได้

- ข้อมูลมีขนาดและโครงสร้างอย่างไร
- แนวโน้มหลักของตัวแปรสำคัญเป็นอย่างไร
- มีความสัมพันธ์เบื้องต้นระหว่างตัวแปรหรือไม่
- มีความผิดปกติที่กระทบการตีความหรือไม่

เครื่องมือที่แนะนำใน Colab

- `pandas` สำหรับสรุปข้อมูล
- `matplotlib` / `seaborn` สำหรับ visualization เบื้องต้น

ตัวอย่าง Prompt สำหรับ EDA

EDA เบื้องต้น

ช่วยเขียนโค้ด Python เพื่อสรุปข้อมูลเบื้องต้น เช่น ขนาดข้อมูล, ค่ากลาง, การกระจายตัว และสร้างกราฟเชิงสำรวจ เช่น histogram ของเวลารอคิว และ scatter plot ของเวลารอคิวเทียบกับอายุ พร้อมอธิบายโค้ดที่ละบรรทัด"

ความสัมพันธ์เบื้องต้น

ช่วยเขียนโค้ด Python เพื่อสร้างกราฟ scatter plot แสดงความสัมพันธ์ระหว่างเวลารอคิวและอายุ พร้อมคำนวณค่า correlation และอธิบายโค้ดที่ละบรรทัด"

Workshop 4 — EDA Pipeline

เปิด Notebook สำหรับรันบน Colab  [Open in Colab](#)

GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-04-eda-pipeline.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ใช้ Titanic dataset ที่ผ่าน Data Preparation แล้ว
2. กำหนดคำถามการวิเคราะห์ 2-3 ข้อ
3. ทำ Data Quality Check และปรับข้อมูล
4. ทำ EDA และสรุปข้อค้นพบเบื้องต้น

Workshop 5 — Population Statistics Pipeline

โจทย์: EDA ข้อมูลประชากร Dataset: ข้อมูลประชากรจากสำนักงานสถิติแห่งชาติ (NSO)

เปิด Notebook สำหรับรันบน Colab  [Open in Colab](#)

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ade8280ab18a05&limit=5000

1. ดึงข้อมูลประชากรรายจังหวัดจาก NSO Open Data API
2. ตรวจสอบคุณภาพข้อมูลและจัดรูปแบบให้เหมาะสม
3. ทำความเข้าใจข้อมูลและกำหนดคำถามเพื่อการวิเคราะห์
4. ทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ
5. วิเคราะห์ตามคำถามที่กำหนดและสรุป Insight ที่ได้จากข้อมูล

โครงสร้างข้อมูล NSO Dataset

ฟิลด์	ชนิด	ตัวอย่างค่า	ความหมาย
year	numeric	2533 , 2543 , 2553	ปีพุทธศักราช
region	text	ทั่วประเทศ , กลาง	ภาค
province	text	รวม , กรุงเทพมหานคร	จังหวัด
area	text	รวม , ในเขตเทศบาล	ประเภทพื้นที่
sex	text	รวม , ชาย , หญิง	เพศ
age_group	text	รวม , 0-4	กลุ่มอายุ
value	numeric	54548530	จำนวนประชากร (คน)

Total records: 38,720 | ปีข้อมูล: พ.ศ. 2533-ปัจจุบัน

Hint: Get Data with Colab + AI

Prompt ตัวอย่างสำหรับดึงข้อมูลจาก NSO API

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้
`https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000`
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

link สำรอง กรณี url ด้านบนมีปัญหา:

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้
`https://raw.githubusercontent.com/toche7/DataSets/refs/heads/main/nso_population.csv`
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

Homework — Household Finance Analysis Pipeline

โจทย์: วิเคราะห์ฐานะทางการเงินครัวเรือนไทยจาก NSO Open Data

Dataset		resource_id
ชุดที่ 1	ค่าใช้จ่ายเฉลี่ยต่อเดือนของครัวเรือน จำแนกตามประเภทค่าใช้จ่าย	697c9b29-d937-4c4e-9d9f-122ff085488b
ชุดที่ 2	หนี้สินเฉลี่ยต่อครัวเรือน จำแนกตามวัตถุประสงค์การกู้ยืม	89cc71ae-f596-4307-b38f-10d61d084801

ความต้องการ:

- 1. ดึงข้อมูลจาก 2 ชุดนี้มาใน Colab ด้วย AI ช่วยเขียนโค้ด
- 2. คำนวณ **สัดส่วนหนี้สิน/ค่าใช้จ่าย** จำแนกตามสถานะทางเศรษฐกิจสังคม
- 3. หาจังหวัดที่มีภาระหนี้สูงสุด / ต่ำสุด
- 4. สร้าง Summary Report ส่ง Email อัตโนมัติ

โครงสร้างข้อมูล: ชุดที่ 1 — ค่าใช้จ่ายครัวเรือน

ฟิลด์	ชนิด	ตัวอย่างค่า
year	text	"2566"
province	text	"กรุงเทพมหานคร" , "เชียงใหม่"
soc_eco_class1	text	"ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..."
soc_eco_class2	text	รายละเอียดสถานะ เช่น "ผู้จัดการนักวิชาการ..."
type_expenditure1	text	"ค่าใช้จ่ายเพื่อการอุปโภคบริโภค" / "ค่าใช้จ่ายทั้งสิ้นต่อเดือน"
type_expenditure2	text	"อาหารและเครื่องดื่ม" , "ที่อยู่อาศัย..." , "การศึกษา"
value	numeric	21740.00 (บาท/เดือน)

โครงสร้างข้อมูล: ชุดที่ 2 — หนี้สินครัวเรือน

ฟิลด์	ชนิด	ตัวอย่างค่า
year	text	"2566"
province	text	"กรุงเทพมหานคร" , "สมุทรปราการ"
soc_eco_class1	text	"ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..."
soc_eco_class2	text	รายละเอียดสถานะ เช่น "คนงานด้านการขนส่ง..."
hhdebt_totaldebt	text	"จำนวนครัวเรือนทั้งสิ้น" / "จำนวนหนี้สินเฉลี่ยต่อครัวเรือน"
purpose_source_bor	text	"จำนวนหนี้สินเฉลี่ยต่อครัวเรือน" / "ใช้ซื้อ/เช่าซื้อบ้าน..." / "หนี้ในระบบ"
value	numeric	300000.00 (บาท) หรือ จำนวนครัวเรือน
unit	text	"บาท" หรือ "ครัวเรือน"

Hint: Get Data with Colab + AI

prompt

```
ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้  
https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=  
697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000  
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย
```

คำใช้ง่ายคร่าวๆ

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000

ห้สืครว้

https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=89cc71ae-f596-4307-b38f-10d61d084801&limit=5000

ทว้ทลดผ่าน browser

หาก url ด้านบนมีปัญหาสามารถใช้ เปิดจาก browser แล้วดาวน์โหลดเป็นไฟล์ CSV/JSON จากนั้นอัปโหลดขึ้น Colab ได้เช่นกัน

สรุปขั้นตอนการวิเคราะห์ข้อมูลด้วย AI ใน Colab

1. กำหนดคำถามการวิเคราะห์ที่ชัดเจน
2. ดึงข้อมูลจากแหล่งที่มา (เช่น NSO API) ด้วย AI ช่วยเขียนโค้ด
3. ตรวจสอบและเตรียมข้อมูลให้พร้อมสำหรับการวิเคราะห์
4. ทำ EDA เพื่อเข้าใจข้อมูลและค้นหา Insight เบื้องต้น
5. สรุปผลลัพธ์และเตรียมข้อมูลสำหรับการนำเสนอในขั้นตอนถัดไป

คำศัพท์ที่ควรรู้เพื่อการเขียน prompt ด้านการวิเคราะห์ข้อมูล

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Missing values	ค่าที่ขาดหายไปข้อมูล	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ missing values ในคอลัมน์ <code>age</code> "
Outliers	ค่าที่ผิดปกติที่อาจเกิดจากข้อผิดพลาดหรือเหตุการณ์พิเศษ	"ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ outliers ในคอลัมน์ <code>waiting_time</code> "
Correlation	ความสัมพันธ์ระหว่างตัวแปรสองตัว	"ช่วยเขียนโค้ด Python เพื่อคำนวณค่า correlation ระหว่างเวลารอคิวและอายุ"
DataFrame	โครงสร้างข้อมูลใน Python ที่ใช้เก็บข้อมูลในรูปแบบตาราง	"ช่วยเขียนโค้ด Python ดึงข้อมูลจาก API มาเก็บใน DataFrame ชื่อ df"
EDA (Exploratory Data Analysis)	กระบวนการสำรวจและวิเคราะห์ข้อมูลเบื้องต้นเพื่อเข้าใจโครงสร้างและแนวโน้มของข้อมูล	"ช่วยเขียนโค้ด Python เพื่อทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ"

คำศัพท์ที่ควรรู้ (ต่อ)

คำศัพท์	ความหมาย	ตัวอย่างการใช้ใน prompt
Tidy data	รูปแบบข้อมูลที่มีโครงสร้างชัดเจน โดยมี 1 ตัวแปรต่อ 1 คอลัมน์ และ 1 แถวต่อ 1 รายการ	"ช่วยเขียนโค้ด Python เพื่อจัดตารางข้อมูลให้อยู่ในรูปแบบ tidy data"
API (Application Programming Interface)	ชุดของคำสั่งและโปรโตคอลที่ใช้ในการเข้าถึงและสื่อสารกับบริการหรือแหล่งข้อมูล	"ช่วยเขียนโค้ด Python ดึงข้อมูลจาก NSO API มาเก็บใน DataFrame ชื่อ df"
Visualization	การสร้างภาพกราฟิกเพื่อสื่อสารข้อมูลและผลลัพธ์จากการวิเคราะห์	"ช่วยเขียนโค้ด Python เพื่อสร้างกราฟ histogram ของเวลารอคิว"
Summary Report	รายงานสรุปผลลัพธ์จากการวิเคราะห์ข้อมูล	"ช่วยเขียนโค้ด Python เพื่อสร้าง Summary Report จากผลการวิเคราะห์และส่ง Email อัตโนมัติ"

สรุป Session 02

- เริ่มจากโจทย์ที่ชัด ก่อนลงมือกับเครื่องมือ
- คุณภาพข้อมูลกำหนดคุณภาพของ Insight
- ใช้ AI เป็นผู้ช่วยคิดและเร่งงาน แต่ต้องมีการตรวจสอบ
- EDA ที่ดีคือฐานสำคัญของการทำ visualization และรายงาน

Q&A

เตรียมต่อ Session 03: Data Visualization with Gemini