



## Session 02

# การสำรวจและวิเคราะห์ข้อมูลด้วย Generative AI และ Google Colab

Stat on Campus: Data innovators

Turning data into impact for public sector

Taweesak Samanchuen, Ph.D.

Mahidol University

# วัตถุประสงค์ของ Session

---

เมื่อจบช่วงนี้ ผู้เข้าอบรมสามารถ:

1. เริ่มใช้งาน Google Colab ได้ แม้ไม่เคยใช้งานมาก่อน
2. เข้าใจบทบาทของ AI ภายใน workflow การวิเคราะห์ข้อมูลใน Colab
3. แปลงโจทย์เชิงนโยบายเป็นคำถามเชิงข้อมูลได้
4. ตรวจสอบและเตรียมข้อมูลก่อนวิเคราะห์ได้เป็นระบบ
5. ใช้ Generative AI ช่วยสำรวจข้อมูลเบื้องต้นได้

# สร้างภาพด้วย Gemini

---

## Prompt

สร้างภาพ super hero ของตัวฉันเองในสไตล์การ์ตูนญี่ปุ่น พร้อมฉากหลังเป็นเมืองใหญ่ในยามค่ำคืน และใส่ข้อความ "AI Data Hero" ที่ด้านล่างของภาพ

- เขียน prompt ตามตัวอย่างนี้
- แบนรูปภาพของคุณเองเพื่อให้ AI สร้างภาพ super hero ที่มีลักษณะคล้ายคุณ

# ทดลองวิเคราะห์ข้อมูลด้วย Gemini

---

1. ดาวน์โหลดไฟล์ presidents.csv ที่  
[https://github.com/toche7/DataSets/blob/main/president\\_heights.csv](https://github.com/toche7/DataSets/blob/main/president_heights.csv)
2. เปิดใช้งาน gemini.google.com
3. เปิด chat ใหม่และ add ไฟล์ president\_heights.csv ที่ดาวน์โหลดจาก GitHub
4. พิมพ์ prompt เช่น

ช่วยวิเคราะห์ข้อมูลความสูงของประธานาธิบดีในไฟล์นี้ และตอบคำถามต่อไปนี้: ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุด พร้อมสร้างกราฟการกระจายความสูงด้วย

# เปรียบเทียบที่ได้จาก Super Hero กับภาพ Histogram

---

- ภาพ super hero เป็นผลลัพธ์จากการใช้ AI สร้างภาพตามคำอธิบายที่ให้ไป ซึ่งเป็นการสร้างสรรค์ที่ไม่จำกัดและมีความยืดหยุ่นสูง
- ภาพ Histogram เป็นการแสดงข้อมูลเชิงสถิติที่แสดงการกระจายของข้อมูล ซึ่งมีความแม่นยำและเป็นทางการมากกว่า
- ทั้งสองภาพมีจุดประสงค์และการใช้งานที่แตกต่างกัน โดยภาพ super hero เน้นความสร้างสรรค์และการสื่อสารที่น่าสนใจ ในขณะที่ Histogram เน้นการวิเคราะห์ข้อมูลและการสื่อสารข้อมูลเชิงปริมาณอย่างชัดเจน

## ใช้เทคโนโลยีที่ต่างกันคือ

- ภาพ super hero ใช้ Generative AI (model: nano-Banana) ในการสร้างสรรค์ภาพตามคำอธิบายที่ให้ไป
- ภาพ Histogram ใช้เทคนิคการวิเคราะห์ข้อมูลและการสร้างกราฟจากข้อมูลที่มีอยู่แล้ว โดยอาจใช้เครื่องมือเช่น Python, R หรือซอฟต์แวร์วิเคราะห์ข้อมูลอื่น ๆ ในการสร้างกราฟนี้

# Colab คืออะไร ทำไมต้องใช้ Colab ในการวิเคราะห์ข้อมูลด้วย AI

## Colab คืออะไร

- แพลตฟอร์มโน้ตบุ๊กออนไลน์ที่ Google ให้บริการฟรี
- รองรับการเขียนโค้ด Python และการใช้ AI ช่วยเขียนโค้ดได้ในทีเดียว
- เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความยืดหยุ่นและตรวจสอบได้

## สิ่งที่ผู้เรียนส่วนใหญ่กังวล

- ไม่เคยเขียนโค้ดมาก่อน
- ไม่แน่ใจว่าจะเริ่มจากปุ่มไหน
- กลัวพิมพ์ผิดแล้วใช้งานต่อไม่ได้



# ทำไม Session นี้ต้องใช้ Colab (ไม่ใช่ AI Chat โดยตรง)

## เหตุผลหลัก

1. **ทำงานวิเคราะห์ได้จริง:** Colab ช่วยให้เราทำงานกับข้อมูลจริงได้ ตั้งแต่การโหลดข้อมูล, ทำความสะอาด, วิเคราะห์ และสร้างกราฟในที่เดียว
2. **ตรวจสอบได้:** ทุกขั้นตอนการวิเคราะห์ถูกบันทึกใน Notebook เดียว ทำให้สามารถตรวจสอบย้อนกลับและทำซ้ำได้ง่าย
3. **เรียนรู้การใช้ AI ใน workflow จริง:** การใช้ AI ช่วยเขียนโค้ดใน Colab เป็นทักษะที่สำคัญในการทำงานวิเคราะห์ข้อมูลยุคใหม่ ซึ่งไม่สามารถเรียนรู้ได้จากการใช้ AI Chat อย่างเดียว

## สรุป

AI Chat อย่างเดียว "ตอบได้เร็ว" แต่ Colab + AI "ทำงานวิเคราะห์ได้จริงและตรวจสอบได้"

# เปรียบเทียบ: AI Chat โดยตรง vs Colab + AI

| ประเด็น                | AI Chat โดยตรง         | Colab + AI            |
|------------------------|------------------------|-----------------------|
| การเก็บขั้นตอน         | กระจัดกระจายตามบทสนทนา | อยู่ใน Notebook เดียว |
| การทำซ้ำผลลัพธ์        | ทำได้ยาก               | ทำได้ง่าย (Run all)   |
| การตรวจสอบย้อนกลับ     | จำกัด                  | ชัดเจนและตรวจสอบได้   |
| ความพร้อมใช้งานหน้างาน | ปานกลาง                | สูง                   |

สรุป: Colab + AI เหมาะสำหรับการวิเคราะห์ข้อมูลที่ต้องการความถูกต้องและตรวจสอบได้ ในขณะที่ AI Chat เหมาะสำหรับการตอบคำถามหรือสร้างโค้ดอย่างรวดเร็วในขั้นตอนแรก



# Workshop 1: Quick Start Colab (สำหรับผู้เริ่มต้น)

---

## 5 ขั้นตอนแรกที่ต้องทำ

1. ไปที่ <https://colab.research.google.com/> และเลือก "New Notebook"
2. ตั้งชื่อไฟล์ให้สื่อความหมายของโจทย์
3. ทดลองใช้งาน Code Cell: เช่น `x = 10; y = 20; print(x + y)`
4. ทดลองใช้งาน Text Cell: เขียนคำอธิบายสั้นๆ ว่า "นี่คือการทดสอบ Text Cell"
5. ทดลอง upload ข้อมูล : presidents.csv จากเครื่องขึ้น Colab (ไอคอนโฟลเดอร์ > Upload)  
[https://github.com/toche7/DataSets/blob/main/president\\_heights.csv](https://github.com/toche7/DataSets/blob/main/president_heights.csv)
6. รันโค้ดอ่านไฟล์ด้วย pandas:


## กติกาในคาบ

- ไม่ต้องกลัวพิมพ์ผิด แก้ไขได้เสมอ

# ภาพรวมหน้าจอ Gemini in Colab

## จุดที่ผู้เรียนควรรู้ก่อนเริ่ม

- พื้นที่เขียนโค้ดอยู่ใน Code Cell
- คำสั่งอธิบายงานให้ AI อยู่ใน Text/Prompt
- กดรันทีละเซลล์เพื่อเช็คผลลัพธ์ทันที
- ถ้าผลไม่ถูกต้อง ให้ปรับ prompt แล้วรันใหม่



# ตัวอย่างโค้ดอ่านไฟล์ CSV ใน Colab ด้วย AI ช่วยเขียน

---

```
import pandas as pd
df = pd.read_csv('/content/president_heights.csv')
print(df.head())
```

# การใช้ Gemini ใน Colab

---

## 1. Predict next word/code

- พิมพ์โค้ดครึ่งหนึ่งแล้วกด Tab เพื่อให้ AI ช่วยเติมโค้ดที่เหลือ
- เหมาะสำหรับโค้ดที่คุ้นเคยแต่ต้องการความรวดเร็ว
- พิมพ์ comment อธิบายสิ่งที่ต้องการ แล้วกด Tab เพื่อให้ AI ช่วยเขียนโค้ด

## 2. Generate code from prompt

- พิมพ์คำอธิบายงานที่ต้องการ เช่น "ช่วยเขียนโค้ด Python สำหรับอ่านไฟล์ CSV และตรวจสอบ missing values"
- AI จะสร้างโค้ดให้ตามคำอธิบาย และสามารถปรับแต่งได้ตามต้องการ
- เหมาะสำหรับงานที่ไม่คุ้นเคยหรือซับซ้อน

# Prompt พื้นฐานที่ใช้กับ AI ใน Colab

---

## Template Prompt

"ช่วยเขียนโค้ด Python สำหรับ [งานที่ต้องการ] โดยใช้ pandas พร้อมอธิบายทีละบรรทัด และให้ตรวจสอบข้อผิดพลาดที่พบบ่อย"

## ตัวอย่างงาน

- อ่านไฟล์ CSV และตรวจ missing values
- แปลงชนิดข้อมูลวันที่
- สรุปสถิติเบื้องต้นและกราฟพื้นฐาน


# Workshop 2: เตรียมข้อมูลและสำรวจข้อมูลด้วย AI

---

## กิจกรรมฝึกปฏิบัติ

1. ใช้ข้อมูล president\_heights.csv ที่อัปโหลดใน Colab
2. กำหนดคำถามการวิเคราะห์ 2-3 ข้อ เช่น ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุดของประธานาธิบดี
3. เขียน prompt เพื่อให้ AI เพื่อวิเคราะห์ข้อมูลและตอบคำถามเหล่านั้น
4. เขียน prompt เพื่อให้ AI ช่วยสร้างกราฟแสดงการกระจายความสูงของประธานาธิบดี

# ตัวอย่างรูปกราฟการกระจายความสูงของประธานาธิบดีที่สร้างด้วย AI



# ภาพรวมเนื้อหา

---

1. ปูพื้นฐาน Colab สำหรับผู้เริ่มต้น
2. ทดลองใช้ Colab + AI
3. **การกำหนดโจทย์การวิเคราะห์ข้อมูล**
4. การเตรียมข้อมูลสำหรับการวิเคราะห์
5. Exploratory Data Analysis (EDA)
6. Workshop 2: เตรียมข้อมูลและสำรวจข้อมูลด้วย AI



# 1) การกำหนดโจทย์การวิเคราะห์ข้อมูล


## จาก "ปัญหางาน" สู่ "คำถามข้อมูล"

- ระบุเป้าหมายเชิงนโยบาย/บริการประชาชน
- นิยามตัวชี้วัดที่สะท้อนผลลัพธ์
- กำหนดขอบเขตข้อมูล: เวลา พื้นที่ หน่วยงาน
- เขียนคำถามที่ตอบได้ด้วยข้อมูลเชิงปริมาณ

## ตัวอย่างคำถาม

ปัจจัยใดสัมพันธ์กับความล่าช้าในการให้บริการมากที่สุด?

### From Policy Problem to Data Question



## 2) การเตรียมข้อมูลสำหรับการวิเคราะห์

---

### Data Quality Checklist

- Missing values และค่าผิดปกติรูปแบบ: เช่น คอลัมน์อายุว่าง, วันที่บันทึกเป็นทั้ง 2026-01-05 และ 05/01/2026
- ความซ้ำซ้อนของรายการข้อมูล: เช่น เลขคำขอเดียวกันถูกบันทึกซ้ำ 2 แถว ทำให้ยอดนับสูงเกินจริง
- ความสอดคล้องของหน่วยและรหัสข้อมูล: เช่น จบประมาณบางแถวเป็นบาท บางแถวเป็นพันบาท หรือรหัสจังหวัด 10 ปนกับ BKK
- Outliers ที่ควรตรวจสอบเพิ่มเติม: เช่น เวลารอคิว 1,200 นาที อาจเป็นค่าพิมพ์ผิดหรือเหตุการณ์พิเศษที่ต้องแยกวิเคราะห์

## 2) การเตรียมข้อมูลสำหรับการวิเคราะห์ (ต่อ)

---

### Data Preparation

- แปลงชนิดข้อมูลให้เหมาะสม: เช่น แปลงคอลัมน์ `service_date` จากข้อความเป็นชนิดวันที่ และแปลง `waiting_time` เป็นตัวเลข
- สร้างคอลัมน์ใหม่เพื่อการวิเคราะห์: เช่น คำนวณ `waiting_time_min` และสร้าง `is_weekend` เพื่อดูผลต่างวันทำการ/วันหยุด
- จัดตารางให้อยู่ในรูปแบบ tidy data: เช่น แยกคอลัมน์ที่รวมหลายค่าให้เหลือ 1 ตัวแปรต่อ 1 คอลัมน์ และ 1 แถวต่อ 1 รายการบริการ

# ตัวอย่าง Prompt สำหรับ Data Preparation

---

## missing values และค่าผิดปกติ

ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ missing values ในคอลัมน์ `age` และแปลงคอลัมน์ `service\_date` ให้เป็นชนิดวันที่ในรูปแบบ YYYY-MM-DD พร้อมอธิบายโค้ดที่ละบรรทัด

## ความซ้ำซ้อนของรายการข้อมูล

ช่วยเขียนโค้ด Python เพื่อตรวจสอบและลบแถวที่มีเลขซ้ำกันในคอลัมน์ `request\_id` พร้อมอธิบายโค้ดที่ละบรรทัด"

### 3) Exploratory Data Analysis (EDA)

---

#### สิ่งที่ต้องตอบให้ได้

- ข้อมูลมีขนาดและโครงสร้างอย่างไร
- แนวโน้มหลักของตัวแปรสำคัญเป็นอย่างไร
- มีความสัมพันธ์เบื้องต้นระหว่างตัวแปรหรือไม่
- มีความผิดปกติที่กระทบการตีความหรือไม่

#### เครื่องมือที่แนะนำใน Colab

- `pandas` สำหรับสรุปข้อมูล
- `matplotlib` / `seaborn` สำหรับ visualization เบื้องต้น

# ตัวอย่าง Prompt สำหรับ EDA

## EDA เบื้องต้น

ช่วยเขียนโค้ด Python เพื่อสรุปข้อมูลเบื้องต้น เช่น ขนาดข้อมูล, ค่ากลาง, การกระจายตัว และสร้างกราฟเชิงสำรวจ เช่น histogram ของเวลารอคิว และ scatter plot ของเวลารอคิวเทียบกับอายุ พร้อมอธิบายโค้ดที่ละบรรทัด"

## ความสัมพันธ์เบื้องต้น

ช่วยเขียนโค้ด Python เพื่อสร้างกราฟ scatter plot แสดงความสัมพันธ์ระหว่างเวลารอคิวและอายุ พร้อมคำนวณค่า correlation และอธิบายโค้ดที่ละบรรทัด"

# Workshop 3

---

## กิจกรรมฝึกปฏิบัติ

1. รับโจทย์ข้อมูลภาครัฐตัวอย่าง
2. กำหนดคำถามการวิเคราะห์ 2-3 ข้อ
3. ทำ Data Quality Check และปรับข้อมูล
4. ทำ EDA และสรุปข้อค้นพบเบื้องต้น

## ผลลัพธ์ที่คาดหวัง

- Notebook ที่มี workflow ชัดเจน
- สรุป Insight ระดับต้นเพื่อใช้ต่อใน Session ถัดไป

# Workshop 3.1 — Population Statistics Pipeline

---

โจทย์: EDA ข้อมูลประชากร

**Dataset:** ข้อมูลประชากรจากสำนักงานสถิติแห่งชาติ (NSO)

[https://catalog.nso.go.th/api/3/action/datastore\\_search?resource\\_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000](https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000)

1. ดึงข้อมูลประชากรรายจังหวัดจาก NSO Open Data API
2. ตรวจสอบคุณภาพข้อมูลและจัดรูปแบบให้เหมาะสม
3. ทำความเข้าใจข้อมูลและกำหนดคำถามเพื่อการวิเคราะห์
4. ทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ
5. วิเคราะห์ตามคำถามที่กำหนดและสรุป Insight ที่ได้จากข้อมูล



# โครงสร้างข้อมูล NSO Dataset

| ฟิลด์     | ชนิด    | ตัวอย่างค่า         | ความหมาย          |
|-----------|---------|---------------------|-------------------|
| year      | numeric | 2533 , 2543 , 2553  | ปีพุทธศักราช      |
| region    | text    | ทั่วประเทศ , กลาง   | ภาค               |
| province  | text    | รวม , กรุงเทพมหานคร | จังหวัด           |
| area      | text    | รวม , ในเขตเทศบาล   | ประเภทพื้นที่     |
| sex       | text    | รวม , ชาย , หญิง    | เพศ               |
| age_group | text    | รวม , 0-4           | กลุ่มอายุ         |
| value     | numeric | 54548530            | จำนวนประชากร (คน) |

Total records: 38,720 | ปีข้อมูล: พ.ศ. 2533-ปัจจุบัน

## Hint: Get Data with Colab + AI

---

### Prompt ตัวอย่างสำหรับดึงข้อมูลจาก NSO API

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้  
`https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=57ff7cd9-27e3-4dc5-b6ad-e8280ab18a05&limit=5000`  
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

link สำรอง กรณี url ด้านบนมีปัญหา:

ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้  
`https://raw.githubusercontent.com/toche7/DataSets/refs/heads/main/nso_population.csv`  
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย

# Workshop 3.2 — Household Finance Analysis Pipeline

โจทย์: วิเคราะห์ฐานะทางการเงินครัวเรือนไทยจาก NSO Open Data

| Dataset  |                                                               | resource_id                          |
|----------|---------------------------------------------------------------|--------------------------------------|
| ชุดที่ 1 | ค่าใช้จ่ายเฉลี่ยต่อเดือนของครัวเรือน จำแนกตามประเภทค่าใช้จ่าย | 697c9b29-d937-4c4e-9d9f-122ff085488b |
| ชุดที่ 2 | หนี้สินเฉลี่ยต่อครัวเรือน จำแนกตามวัตถุประสงค์การกู้ยืม       | 89cc71ae-f596-4307-b38f-10d61d084801 |

## ความต้องการ:

- ดึงข้อมูลจาก 2 ชุดนี้มาใน Colab ด้วย AI ช่วยเขียนโค้ด
- คำนวณ **สัดส่วนหนี้สิน/ค่าใช้จ่าย** จำแนกตามสถานะทางเศรษฐกิจสังคม
- หาจังหวัดที่มีภาระหนี้สูงสุด / ต่ำสุด
- สร้าง Summary Report ส่ง Email อัตโนมัติ

# โครงสร้างข้อมูล: ชุดที่ 1 — ค่าใช้จ่ายครัวเรือน

| ฟิลด์             | ชนิด    | ตัวอย่างค่า                                                     |
|-------------------|---------|-----------------------------------------------------------------|
| year              | text    | "2566"                                                          |
| province          | text    | "กรุงเทพมหานคร" , "เชียงใหม่"                                   |
| soc_eco_class1    | text    | "ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..." |
| soc_eco_class2    | text    | รายละเอียดสถานะ เช่น "ผู้จัดการนักวิชาการ..."                   |
| type_expenditure1 | text    | "ค่าใช้จ่ายเพื่อการอุปโภคบริโภค" / "ค่าใช้จ่ายทั้งสิ้นต่อเดือน" |
| type_expenditure2 | text    | "อาหารและเครื่องดื่ม" , "ที่อยู่อาศัย..." , "การศึกษา"          |
| value             | numeric | 21740.00 (บาท/เดือน)                                            |

# โครงสร้างข้อมูล: ชุดที่ 2 — หนี้สินครัวเรือน

| ฟิลด์              | ชนิด    | ตัวอย่างค่า                                                                 |
|--------------------|---------|-----------------------------------------------------------------------------|
| year               | text    | "2566"                                                                      |
| province           | text    | "กรุงเทพมหานคร" , "สมุทรปราการ"                                             |
| soc_eco_class1     | text    | "ลูกจ้าง" , "ผู้ประกอบการธุรกิจ..." , "ผู้ถือครองทำการเกษตร..."             |
| soc_eco_class2     | text    | รายละเอียดสถานะ เช่น "คนงานด้านการขนส่ง..."                                 |
| hhdebt_totaldebt   | text    | "จำนวนครัวเรือนทั้งสิ้น" / "จำนวนหนี้สินเฉลี่ยต่อครัวเรือน"                 |
| purpose_source_bor | text    | "จำนวนหนี้สินเฉลี่ยต่อครัวเรือน" / "ใช้ซื้อ/เช่าซื้อบ้าน..." / "หนี้ในระบบ" |
| value              | numeric | 300000.00 (บาท) หรือ จำนวนครัวเรือน                                         |
| unit               | text    | "บาท" หรือ "ครัวเรือน"                                                      |

## Hint: Get Data with Colab + AI

---

### prompt

```
ช่วยเขียนโค้ด Python ดึงข้อมูลที่ url นี้  
https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=  
697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000  
มาเก็บใน DataFrame ชื่อ df และแสดงข้อมูล 5 แถวแรก พร้อมอธิบายโครงสร้างข้อมูลให้เข้าใจง่าย
```

### คำใช้ง่ายคร่าวๆ

[https://catalog.nso.go.th/api/3/action/datastore\\_search?resource\\_id=697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000](https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=697c9b29-d937-4c4e-9d9f-122ff085488b&limit=5000)

### ห้สืลคร่าวๆ

[https://catalog.nso.go.th/api/3/action/datastore\\_search?resource\\_id=89cc71ae-f596-4307-b38f-10d61d084801&limit=5000](https://catalog.nso.go.th/api/3/action/datastore_search?resource_id=89cc71ae-f596-4307-b38f-10d61d084801&limit=5000)

### ดาวโหลดผ่าน browser

หาก url ด้านบนมีปัญหาสามารถใช้ เปิดจาก browser แล้วดาวนโหลดเป็นไฟล์ CSV/JSON จากนั้นอัปโหลดขึ้น Colab ได้เช่นกัน

# สรุปขั้นตอนการวิเคราะห์ข้อมูลด้วย AI ใน Colab

---

1. กำหนดคำถามการวิเคราะห์ที่ชัดเจน
2. ดึงข้อมูลจากแหล่งที่มา (เช่น NSO API) ด้วย AI ช่วยเขียนโค้ด
3. ตรวจสอบและเตรียมข้อมูลให้พร้อมสำหรับการวิเคราะห์
4. ทำ EDA เพื่อเข้าใจข้อมูลและค้นหา Insight เบื้องต้น
5. สรุปผลลัพธ์และเตรียมข้อมูลสำหรับการนำเสนอในขั้นตอนถัดไป

# คำศัพท์ที่ควรรู้เพื่อการเขียน prompt ด้านการวิเคราะห์ข้อมูล

| คำศัพท์                         | ความหมาย                                                                         | ตัวอย่างการใช้ใน prompt                                                                       |
|---------------------------------|----------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| Missing values                  | ค่าที่ขาดหายไปข้อมูล                                                             | "ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ missing values ในคอลัมน์ <code>age</code> "    |
| Outliers                        | ค่าที่ผิดปกติที่อาจเกิดจากข้อผิดพลาดหรือเหตุการณ์พิเศษ                           | "ช่วยเขียนโค้ด Python เพื่อตรวจสอบและจัดการกับ outliers ในคอลัมน์ <code>waiting_time</code> " |
| Correlation                     | ความสัมพันธ์ระหว่างตัวแปรสองตัว                                                  | "ช่วยเขียนโค้ด Python เพื่อคำนวณค่า correlation ระหว่างเวลารอคิวและอายุ"                      |
| DataFrame                       | โครงสร้างข้อมูลใน Python ที่ใช้เก็บข้อมูลในรูปแบบตาราง                           | "ช่วยเขียนโค้ด Python ดึงข้อมูลจาก API มาเก็บใน DataFrame ชื่อ df"                            |
| EDA (Exploratory Data Analysis) | กระบวนการสำรวจและวิเคราะห์ข้อมูลเบื้องต้นเพื่อเข้าใจโครงสร้างและแนวโน้มของข้อมูล | "ช่วยเขียนโค้ด Python เพื่อทำ EDA เบื้องต้น เช่น การกระจายตัวของประชากรตามเพศและอายุ"         |



# คำศัพท์ที่ควรรู้ (ต่อ)

| คำศัพท์                                 | ความหมาย                                                                           | ตัวอย่างการใช้ใน prompt                                                                  |
|-----------------------------------------|------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| Tidy data                               | รูปแบบข้อมูลที่มีโครงสร้างชัดเจน โดยมี 1 ตัวแปรต่อ 1 คอลัมน์ และ 1 แถวต่อ 1 รายการ | "ช่วยเขียนโค้ด Python เพื่อจัดตารางข้อมูลให้อยู่ในรูปแบบ tidy data"                      |
| API (Application Programming Interface) | ชุดของคำสั่งและโปรโตคอลที่ใช้ในการเข้าถึงและสื่อสารกับบริการหรือแหล่งข้อมูล        | "ช่วยเขียนโค้ด Python ดึงข้อมูลจาก NSO API มาเก็บใน DataFrame ชื่อ df"                   |
| Visualization                           | การสร้างภาพกราฟิกเพื่อสื่อสารข้อมูลและผลลัพธ์จากการวิเคราะห์                       | "ช่วยเขียนโค้ด Python เพื่อสร้างกราฟ histogram ของเวลารอคิว"                             |
| Summary Report                          | รายงานสรุปผลลัพธ์จากการวิเคราะห์ข้อมูล                                             | "ช่วยเขียนโค้ด Python เพื่อสร้าง Summary Report จากผลการวิเคราะห์และส่ง Email อัตโนมัติ" |

# สรุป Session 02

---

- เริ่มจากโจทย์ที่ชัด ก่อนลงมือกับเครื่องมือ
- คุณภาพข้อมูลกำหนดคุณภาพของ Insight
- ใช้ AI เป็นผู้ช่วยคิดและเร่งงาน แต่ต้องมีการตรวจสอบ
- EDA ที่ดีคือฐานสำคัญของการทำ visualization และรายงาน

# Q&A

เตรียมต่อ Session 03: Data Visualization with Gemini