



Session 03

Data Visualization with Gemini in Colab

Stat on Campus: Data innovators

Turning data into impact for public sector

Taweesak Samanchuen, Ph.D.

Mahidol University

วัตถุประสงค์ของ Session

เมื่อจบช่วงนี้ ผู้เข้าอบรมสามารถ:

1. เลือกประเภทกราฟให้เหมาะกับชนิดข้อมูลและเป้าหมาย
2. ใช้ Gemini in Colab ช่วยออกแบบและสร้างกราฟได้รวดเร็วขึ้น
3. อธิบายความสัมพันธ์ของตัวแปรด้วย correlation และ regression เบื้องต้น
4. ตีความผลจากกราฟอย่างถูกต้องและชัดเจน
5. สื่อสารข้อมูลให้ผู้บริหารและผู้เกี่ยวข้องเข้าใจได้ง่าย

ภาพรวมเนื้อหา

1. Recall: สิ่งที่เราเรียนไปแล้วใน Session 01-02
2. Univariate และ Bivariate Analysis
3. Correlation และ Regression
4. Visualization เพื่อการสื่อสาร
5. Workshop 6: Data Visualization with Gemini in Colab
6. LLM for Data Extraction

1. Recall

1) Recall

- AI and ML
- Colab with AI
- Basic Python for Data Analysis
- Data Preprocessing
- EDA

2. Univariate and Bivariate Analysis

Univariate Analysis

การวิเคราะห์ตัวแปรเดียว


- วิเคราะห์ตัวแปรทีละตัว โดยไม่คำนึงถึงความสัมพันธ์กับตัวแปรอื่น
- เป้าหมาย: ทำความเข้าใจการกระจาย (distribution), ค่ากลาง, และ outlier
- กราฟที่ใช้: Histogram, Boxplot, Bar chart

สถิติ	ความหมาย
Mean / Median	ค่ากลางของข้อมูล
Std Dev	ความผันแปรของข้อมูล
Min / Max	ขอบเขตของข้อมูล

ตัวอย่าง Univariate Analysis

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
# สถิติพื้นฐาน
print(df.describe())
# Histogram
sns.histplot(df["Passenger"], bins=6, kde=True)
plt.title("Number of Passenger")
plt.show()
```


Univariate Analysis: Histogram



Univariate Analysis: Boxplot

- Boxplot แสดงค่ากลาง (median), quartiles, และ outliers ของข้อมูล - ช่วยให้เห็นการกระจายและความไม่สมมาตรของข้อมูล

```
sns.boxplot(data=df, x="Passenger")  
plt.title("Boxplot of Passenger")  
plt.show()
```



Bivariate Analysis

การวิเคราะห์ความสัมพันธ์ระหว่าง 2 ตัวแปร


- วิเคราะห์ว่าตัวแปร 2 ตัวมีความสัมพันธ์กันอย่างไร
- เป้าหมาย: หารูปแบบ (pattern) และแนวโน้มร่วมกัน
- กราฟที่ใช้: Scatter plot, Box plot แยกกลุ่ม, Heatmap

ชนิดข้อมูล	วิธีวิเคราะห์
Numeric + Numeric	Scatter plot, Correlation
Numeric + Categorical	Boxplot, Grouped Bar chart
Categorical + Categorical	Crosstab, Heatmap

ตัวอย่าง Bivariate Analysis

```
# Scatter plot: Passenger vs Fuel Cost
sns.scatterplot(data=df, x="Passenger", y="Fuel Cost")
plt.title("Passenger vs Fuel Cost")
plt.show()


# Correlation matrix
print(df[["Passenger", "Fuel Cost"]].corr())
```



3. Correlation and Regression

Correlation

- Correlation (สหสัมพันธ์) เป็นการวิเคราะห์ความสัมพันธ์ระหว่างข้อมูลตั้งแต่ 2 ตัวขึ้นไปว่ามีความสัมพันธ์กันในระดับใด และมีความสัมพันธ์ในทิศทางใด
- เช่น ความสูงกับน้ำหนักของคน มีความสัมพันธ์กันมากหรือน้อยและมีความสัมพันธ์ในทิศทางเดียวกันหรือตรงกันข้าม



Correlation Coefficient

- Correlation Coefficient คือค่าสถิติอย่างง่ายที่ใช้แสดงว่าความสัมพันธ์ระหว่างข้อมูล ว่ามีค่ามาก น้อยเพียงใดและอยู่ในทิศทางใด
- โดยมีสูตรพื้นฐานที่ใช้กันคือ Pearson Product Moment Correlation Coefficient




$$r = \frac{cov(X, Y)}{(std(X) * std(Y))} \quad (1)$$

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \quad (2)$$

จะใช้ pearson correlation เมื่อข้อมูลเป็น continuous และมีความสัมพันธ์เชิงเส้น ถ้าเป็น categorical จะใช้ spearman correlation หรือ chi-square test แทน

Correlation Coefficient Interpretation

- ค่า r ใกล้ 1 = ไปทิศทางเดียวกัน
- ค่า r ใกล้ -1 = สวนทางกัน
- ค่า r ใกล้ 0 = ความสัมพันธ์เชิงเส้นน้อย



ตัวอย่างการคำนวณ Correlation ด้วย Python


```
import pandas as pd
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
correlation = df["Passenger"].corr(df["Fuel Cost"])
print(f"Correlation between Passenger and Fuel Cost: {correlation:.2f}")
```

Regression

ใช้สร้างสมการทำนาย

$$\hat{y} = \theta_0 + \theta_1 \cdot x_1$$

- θ_1 บอกว่า $\hat{y}$ (Fuel Cost) เปลี่ยนเท่าไรเมื่อ x_1 (Passenger) เพิ่ม 1 หน่วย
- ใช้สื่อสารแนวโน้มและประมาณค่าได้อย่างรวดเร็ว
- ควรตรวจ outlier และ residual ก่อนนำไปใช้จริง



ตัวอย่างโค้ด

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
X = df[["Passenger"]]
y = df["Fuel Cost"]
model = LinearRegression().fit(X, y)
sns.regplot(data=df, x="Passenger", y="Fuel Cost", line_kws={"color": "red"}, ci=98)
plt.title(f"Passenger vs Fuel Cost ( R2= {model.score(X, y):.2f} )")
plt.show()
```

Prompt ที่แนะนำ

ใช้ไฟล์ `cost.xlsx` จาก GitHub นี้

- 1) โหลดข้อมูลด้วย pandas
- 2) สร้าง scatter plot และ regression line
- 3) คำนวณ correlation ระหว่าง Passenger กับ Fuel Cost
- 4) อธิบายผลเป็นภาษาไทยแบบที่ใช้สอนผู้เรียนได้

จุดที่ให้ผู้เรียนสังเกต

- เมื่อ Passenger เพิ่มขึ้น Fuel Cost เปลี่ยนอย่างไร
- เส้น regression อธิบายข้อมูลได้ดีแค่ไหน
- ความสัมพันธ์ที่เห็นเป็นเหตุผลหรือเพียงความสัมพันธ์

4. Visualization เพื่อการสื่อสาร

แพลตฟอร์มที่ใช้ในชั้นเรียน

1. Gemini in Colab: ช่วยคิด วิเคราะห์ และเขียนโค้ดในโน้ตบุ๊กเดียว
2. GitHub Raw CSV: ใช้เป็นแหล่งข้อมูลกลางให้ทุกคนโหลดข้อมูลชุดเดียวกัน
3. Visualization Libraries: ใช้ `pandas`, `matplotlib`, `seaborn`

1) หลักการเลือกประเภทกราฟ


คำถามก่อนเลือกกราฟ

- ต้องการเปรียบเทียบ, แสดงแนวโน้ม, หรือแสดงสัดส่วน?
- ข้อมูลเป็นหมวดหมู่, ตัวเลขต่อเนื่อง, หรือเวลา?
- ผู้ชมต้องการตัดสินใจเรื่องใดจากกราฟนี้?


แนวทางใช้งาน

- Bar chart: เปรียบเทียบค่าระหว่างกลุ่ม
- Line chart: แนวโน้มตามเวลา
- Scatter plot: ความสัมพันธ์ระหว่างตัวแปร
- Heatmap: รูปแบบ/ความเข้มข้นในหลายมิติ


Bar chart: เปรียบเทียบค่าระหว่างกลุ่ม




Line chart: แนวโน้มตามเวลา




Pie chart: แสดงสัดส่วนของแต่ละกลุ่มในภาพรวม



Scatter plot: ความสัมพันธ์ระหว่างตัวแปร



Heatmap: รูปแบบ/ความเข้มข้นในหลายมิติ



ตัวอย่าง: คำถามแบบไหน ใช้กราฟอะไร

ใช้ชุดข้อมูลผู้รับบริการภาครัฐรายเดือน

คำถาม	กราฟที่เหมาะสม	สิ่งที่อยากเห็น
จังหวัดไหนมีผู้รับบริการมากที่สุดในเดือนล่าสุด	Bar chart	เปรียบเทียบขนาดระหว่างจังหวัด
จำนวนผู้รับบริการเพิ่มหรือลดลงอย่างไรใน 6 เดือน	Line chart	แนวโน้มและจังหวะการเปลี่ยนแปลง
เวลารอที่ลดลง ทำให้ความพึงพอใจสูงขึ้นหรือไม่	Scatter plot	ความสัมพันธ์ระหว่าง 2 ตัวแปร
จังหวัดใดมีจำนวนผู้รับบริการสูงต่อเนื่องหลายเดือน	Heatmap	จุดที่เข้ม/อ่อนในหลายมิติ

ตัวอย่างการตีความจากข้อมูลเดียวกัน

ตัวอย่างข้อความสรุปที่ “ดีพอสำหรับนำเสนอ”

- Bar chart: กรุงเทพมหานครมีผู้รับบริการสูงสุดในเดือนล่าสุด จึงอาจต้องจัดทรัพยากรหน้าจุดบริการมากกว่าจังหวัดอื่น
- Line chart: ทุกจังหวัดมีแนวโน้มผู้รับบริการเพิ่มขึ้นต่อเนื่อง สะท้อนว่าความต้องการบริการยังขยายตัว
- Scatter plot: เมื่อเวลารอลดลง ความพึงพอใจมีแนวโน้มสูงขึ้น แต่ยังไม่พอจะสรุปว่าเป็นเหตุโดยตรง
- Heatmap: เชียงใหม่และกรุงเทพมหานครมีความเข้มสูงหลายเดือนต่อเนื่อง จึงควรติดตามกำลังคนและช่องทางออนไลน์ควบคู่กัน

สิ่งที่ต้องระวัง

- อย่าสรุปว่า “เวลารอลดลงทำให้ความพึงพอใจสูงขึ้นแน่นอน” โดยไม่มีปัจจัยอื่นประกอบ
- อย่าดูเฉพาะจังหวัดที่ค่าสูงสุด แต่ให้ดูอัตราการเปลี่ยนแปลงและบริบทของพื้นที่ด้วย

2) Data Visualization เพื่อการสื่อสาร

หลักการสำคัญ

- ชัดเจน: ลดองค์ประกอบที่ไม่จำเป็น
- ถูกต้อง: ไม่บิดเบือนสเกลหรือบริบท
- มีสาร: ทุกกราฟต้องตอบคำถามหลักได้

โครงสร้างการเล่าเรื่องข้อมูล

1. บริบทของปัญหา
2. หลักฐานจากข้อมูล
3. Insight และข้อเสนอแนะ

กรณีศึกษาประสิทธิภาพการบริการ


1. บริบทของปัญหา (Context)

เราต้องการตรวจสอบว่า 'จำนวนผู้รับบริการที่เพิ่มขึ้น ส่งผลกระทบต่อคุณภาพการบริการและความพึงพอใจหรือไม่' เพื่อวางแผนการจัดการทรัพยากรในอนาคต

2. หลักฐานจากข้อมูล (Evidence)

ใช้กราฟที่เน้นความชัดเจน โดยลด Grid lines ที่ไม่จำเป็น และเน้นความถูกต้องของสเกล

Case Study: การสื่อสารข้อมูลด้วย Visualization



3) ใช้ Gemini in Colab ช่วยสร้างกราฟ

ตัวอย่างการใช้งาน

- ช่วยร่างโค้ดสร้างกราฟจากตารางข้อมูล
- แนะนำกราฟที่เหมาะสมกับตัวแปรแต่ละชุด
- ช่วยปรับแต่ง label/title/annotation ให้ชัดเจน
- สร้างสรุปข้อความประกอบกราฟอัตโนมัติ

Prompt ที่แนะนำ

Prompt ที่แนะนำ

จากข้อมูลนี้ ช่วยเสนอ 3 กราฟที่เหมาะสม พร้อมเหตุผล และตัวอย่างโค้ด

Prompt ตัวอย่างที่ซับซ้อน

ข้อมูลนี้เป็นจำนวนผู้รับบริการภาครัฐรายเดือน แยกตามจังหวัด

ช่วยเลือกกราฟที่เหมาะสม 4 แบบ โดยอธิบายว่ากราฟแต่ละแบบตอบคำถามผู้บริหารอะไรได้

และเขียนโค้ด Python ที่พร้อมรันใน Colab"

4) การตีความกราฟอย่างมีคุณภาพ

เช็กलिस्टก่อนสรุปผล

- ความแตกต่างที่เห็นมีนัยสำคัญเชิงปฏิบัติหรือไม่
- มีปัจจัยแทรกซ้อนที่ยังไม่ถูกควบคุมหรือไม่
- ข้อสรุปสอดคล้องกับนิยามตัวชี้วัดหรือไม่
- มีข้อจำกัดข้อมูลที่ต้องแจ้งหรือไม่

ข้อผิดพลาดที่พบบ่อย

- สรุปเหตุ-ผลจากความสัมพันธ์เพียงอย่างเดียว
- ใช้กราฟ 3D หรือเอฟเฟกต์ที่ทำให้ตีความคลาดเคลื่อน

5. Workshop 6: Data Visualization with Gemini in Colab

Workshop 6

 Open in Colab

กิจกรรมฝึกปฏิบัติ

1. เลือกคำถามวิเคราะห์จาก Session 02
2. ออกแบบกราฟอย่างน้อย 3 แบบ
3. ใช้ Gemini in Colab ช่วยสร้าง/ปรับโค้ด
4. สรุปข้อความ insight ต่อกราฟละ 1-2 ประโยค

ผลลัพธ์ที่คาดหวัง

- ชุดกราฟที่พร้อมนำเสนอ
- ข้อความอธิบายที่กระชับและใช้งานได้จริง

ติดตั้ง font ภาษาไทยใน Colab

Prompt

ช่วยเขียนโค้ด Python ใน Colab เพื่อดาวน์โหลดและติดตั้งฟอนต์ภาษาไทยที่เหมาะสมกับการสร้างกราฟใน Matplotlib และทดสอบการแสดงผลด้วยข้อความภาษาไทย

- เลือก model ที่มีเก่งในการทำเรื่องนี้เพราะมีความซับซ้อนในการจัดการฟอนต์และการแสดงผลภาษาไทยในกราฟ ซึ่งอาจต้องใช้ความรู้เฉพาะทางในการตั้งค่าฟอนต์ใน Matplotlib และการจัดการกับภาษาไทยใน Python โดยตรง
- ให้เลือกฟอนต์ที่นิยมใช้สำหรับการนำเสนอในภาษาไทย เช่น "TH Sarabun New" หรือ "Kanit" และช่วยเขียนโค้ดที่พร้อมรันได้เลยใน Colab เพื่อให้ผู้เรียนสามารถใช้ฟอนต์นี้ในการสร้างกราฟและแสดงผลภาษาไทยได้อย่างถูกต้อง

ติดตั้ง font ภาษาไทยใน Colab

```
# ดาวน์โหลดฟอนต์ TH Sarabun New

!wget -q https://github.com/Phonbopit/sarabun-webfont/raw/master\
/fonts/thсарunnew-webfont.ttf

import matplotlib as mpl
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# เพิ่มฟอนต์เข้าระบบ Matplotlib

fm.fontManager.addfont('thсарunnew-webfont.ttf')

# ตั้งค่า default font ให้เป็น TH Sarabun New

mpl.rc('font', family='TH Sarabun New')
```

ทดสอบการแสดงผลภาษาไทย

```
# ทดสอบการพล็อตภาษาไทย
plt.figure(figsize=(6, 4))
plt.text(0.5, 0.5, 'สวัสดีภาษาไทย (Thai Language Test)', fontsize=25, ha='center', va='center')
plt.title('ทดสอบการแสดงผลภาษาไทย')
plt.axis('off')
plt.show()
```

ผลลัพธ์ที่คาดหวัง

ทดสอบการแสดงผลภาษาไทย

สวัสดีภาษาไทย (Thai Language Test)

Workshop 6: โหลดข้อมูลจาก GitHub

Dataset สำหรับฝึก

- Raw CSV: <https://raw.githubusercontent.com/toche7/DataSets/main/session-03-workshop-sample-data.csv>
- แพลตฟอร์มหลัก: Gemini in Colab
- เครื่องมือ: `pandas`, `matplotlib`, `seaborn`
- ใช้ชุดข้อมูลเดียวกันเพื่อสร้างกราฟ 4 ประเภท

Prompt ที่ให้ผู้เรียนใช้

โหลดข้อมูลจากไฟล์ CSV นี้ และช่วยสร้างกราฟ 4 ประเภท ได้แก่ bar chart, line chart, scatter plot และ heatmap แยก เป็นภาพ ๆ พร้อมอธิบายว่าแต่ละกราฟตอบคำถามเชิงนโยบายอะไรได้บ้าง และช่วยปรับชื่อกราฟ แยก และสีให้เหมาะกับการนำเสนอผู้บริหาร:

python code ตัวอย่างการโหลดข้อมูลและเริ่มต้นวิเคราะห์

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
url = "https://raw.githubusercontent.com/toche7/DataSets/main/session-03-workshop-sample-data.csv"
df = pd.read_csv(url)
df["เดือน"] = pd.to_datetime(df["เดือน"])
sns.set_theme(style="whitegrid")
df.head()
```

ตัวอย่าง 1-2: Bar และ Line

Bar chart: เปรียบเทียบจังหวัดในเดือนล่าสุด

```
latest = df[df["เดือน"] == df["เดือน"].max()]
sns.barplot(data=latest, x="จังหวัด", y="จำนวนผู้รับบริการทั้งหมด(คน)")
plt.xticks(rotation=15)
plt.title("จำนวนผู้รับบริการทั้งหมด แยกตามจังหวัด")
plt.show()
```

Line chart: แนวโน้มรายเดือนของผู้รับบริการ

```
sns.lineplot(data=df, x="เดือน", y="จำนวนผู้รับบริการทั้งหมด(คน)", hue="จังหวัด", marker="o")
plt.title("แนวโน้มผู้รับบริการรายเดือน")
plt.show()
```

ตัวอย่าง 3-4: Scatter และ Heatmap

Scatter plot: เวลากับความพึงพอใจ

```
sns.scatterplot(data=df, x="เวลารอเฉลี่ย(นาที)", y="ความพึงพอใจ(%)", hue="จังหวัด", s=120)
plt.title("ความสัมพันธ์ระหว่างเวลารอและความพึงพอใจ")
plt.show()
```

Heatmap: ผู้รับบริการตามเดือนและจังหวัด

```
pivot = df.pivot(index="จังหวัด", columns="เดือน", values="จำนวนผู้รับบริการทั้งหมด(คน)")
sns.heatmap(pivot, cmap="YlGnBu", annot=True, fmt=".0f")
plt.title("Heatmap จำนวนผู้รับบริการ")
plt.show()
```

Prompt ให้ Gemini ช่วยต่อยอด

> ใช้ Gemini in Colab กับข้อมูลจากไฟล์ CSV นี้เพื่อสร้าง bar chart, line chart, scatter plot และ heatmap พร้อมอธิบายว่าแต่ละกราฟตอบคำถามเชิงนโยบายอะไรได้บ้าง และช่วยปรับชื่อกราฟ แกน และสีให้เหมาะกับการนำเสนอผู้บริหาร

จุดที่ให้ผู้เรียนสังเกต

- จังหวัดใดมีปริมาณผู้รับบริการสูงสุดอย่างสม่ำเสมอ
- เวลาที่ลดลงสัมพันธ์กับความพึงพอใจหรือไม่
- จังหวัดใดมีโอกาสเพิ่มสัดส่วนบริการออนไลน์ได้อีก

6. LLM for Data Extraction

Workshop 7: LLM for Data Extraction

 Open in Colab

GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-07-llm-data-extraction-groq.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ตั้งค่า Groq API key ใน Colab
2. Extract ข้อมูลแบบมีโครงสร้างจากข้อความที่ไม่มีโครงสร้าง
3. ทำ Sentiment Analysis เป็น positive/neutral/negative
4. สรุปผลลัพธ์เป็นตารางสำหรับนำเสนอ

Unstructured Data Extraction

- We can use LLM to extract structured data from unstructured data sources such as PDF, Word, and Excel files.
- Moreover, we can use LLM to do sentiment analysis, topic modeling, and text summarization.

Connect with LLM for Data Extraction

- We can connect to LLM for example Groq.com
- We are going to use Colab to connect to LLM for data extraction and analysis.
- We need to install the required libraries and set up the API key for authentication.
- We have to apply to Groq.com to get the API key and set it up in Colab.

Demo: Connecting to LLM for Data Extraction

Sentiment Analysis with LLM

- We can use LLM to analyze the sentiment of text data. For example, we can analyze customer reviews, social media posts, and survey responses.
- We can use LLM to classify the sentiment as positive, negative, or neutral.

Demo: Sentiment Analysis with LLM

Q&A

เตรียมต่อ Session 04: AI-Assisted Reporting and Presentation

วิทยากร

ผศ.ดร.ทวิศักดิ์ สมานชื่น

Asst. Prof. Taweesak Samanchuen, Ph.D.

- รองผู้อำนวยการฝ่ายดิจิทัลเทคโนโลยี **MULKC**
- อาจารย์ประจำสาขา **ITM** คณะวิศวกรรมศาสตร์ มหาวิทยาลัยมหิดล
- หัวหน้าโครงการ **CBTU**

 [Profile](#)

 t.samanchuen@gmail.com

 081-441-4906

website: cbtumu.net | facebook: [cbtumu](https://www.facebook.com/cbtumu)

ขอบคุณครับ

ผศ.ดร.ทวิศักดิ์ สมานชื่น