

Session 01

Generative AI for Data Work

หลักสูตร: การใช้ Generative AI เพื่อการวิเคราะห์ข้อมูลสำหรับภาครัฐ

Asst. Prof. Taweesak Samanchuen, Ph.D.

Mahidol University

วัตถุประสงค์การเรียนรู้

- เข้าใจความหมายของ **Generative AI** และ **LLM**
- เข้าใจหลักการทำงานของ **Prompt, Token** และ **Context Window**
- เข้าใจหลักการ **Prompt Engineering** และเทคนิคการปรับ Prompt ให้ได้ผล
- สามารถปรับ Prompt ให้เหมาะกับงานข้อมูลที่ทำอยู่จริง

01

Generative AI and LLM

Using AI to Accelerate Data Work, Not Replace Thinking

AI คืออะไร? (ฉบับ 2 นาที)

AI (Artificial Intelligence)


แบบจำลองสมองที่เรียนรู้จากข้อมูลมหาศาล

Generative AI

AI ที่ **สร้างสิ่งใหม่** ได้ — ข้อความ ภาพ เสียง วิดีโอ

LLM (Large Language Model)

เรียนรู้จาก pattern ของภาษามนุษย์



Generative AI คืออะไร

คำอธิบายแบบสั้นที่สุด

- เป็นกลุ่มของ AI ที่ **สร้างเนื้อหาใหม่** จาก pattern ที่เรียนรู้มา
- เนื้อหาที่สร้างได้อาจเป็น **ข้อความ, รูปภาพ, เสียง, โค้ด, วิดีโอ**
- คำว่า "generate" ไม่ได้แปลว่าคิดเองจากศูนย์ แต่คือสร้าง output ใหม่จากสิ่งที่เคยเรียนรู้

ตัวอย่างที่พบได้บ่อย

- สร้างอีเมลหรือสรุปรายงาน
- สร้างรูปภาพจาก prompt
- สร้างโค้ด Python หรือ SQL
- สร้างข้อความจำลองสำหรับทดสอบระบบ

ตัวอย่างการใช้งาน Generative AI ในปัจจุบัน

สิ่งที่เห็น	จริง ๆ คืออะไร	ตัวอย่างงาน
ChatGPT, Claude, Gemini	ผู้ช่วยสนทนาที่ขับเคลื่อนด้วย LLM	ถามตอบ, สรุป, เขียน SQL
Llama, GPT, Qwen	ตระกูลของ LLM	generate text, classify, extract
Midjourney, DALL-E	Generative AI สำหรับภาพ	สร้างรูปจากข้อความ
Suno	Generative AI สำหรับเสียง/เพลง	สร้าง audio

บริบทของคาบนี้

- เราจะโฟกัส **text-based Generative AI**
- หรือพูดให้ตรงขึ้นคือ **การใช้ LLM กับงานข้อมูล**

แล้ว LLM คืออะไร

ความสัมพันธ์กับ Generative AI

- **LLM = Large Language Model**
- LLM เป็น **หนึ่งประเภทของ Generative AI** ที่เชี่ยวชาญเรื่องภาษา
- ถ้า Generative AI เป็น "หมวดใหญ่" LLM คือ "เครื่องมือย่อย" ที่ใช้สร้างและเข้าใจข้อความ


เปรียบเทียบแบบง่าย

- **Generative AI:** คำรวมของระบบที่สร้าง content ใหม่
- **LLM:** โมเดลที่สร้างและประมวลผล "ภาษา" เป็นหลัก

สรุปสั้น: ทุก LLM เป็น Generative AI แต่ไม่ใช่ทุก Generative AI จะเป็น LLM

Modern Chat AI

สถาปัตยกรรมแบบบอท AI สมัยใหม่ (เช่น ChatGPT, Gemini, Claude)



Token คืออะไร?

Token = หน่วยเล็กที่สุดที่ AI ใช้ "อ่าน" และ "เขียน" ข้อความ — ไม่ใช่คำ แต่เป็นชิ้นส่วนของคำ

ตัวอย่าง (ภาษาอังกฤษ)

- "Hello" = 1 token
- "unbelievable" = 3 tokens
- 1 คำ $\approx$ 0.75 token โดยเฉลี่ย

ตัวอย่าง (ภาษาไทย)

- ภาษาไทยใช้ token มากกว่า EN $\sim$ 2-3x
- "สวัสดี" $\approx$ 3-5 tokens

Token คืออะไร? (ต่อ)

ทำไมต้องรู้?

- **Context Window** วัดเป็น token
- ยิ่ง Prompt ยาว → ใช้ token มาก → เหลือพื้นที่คำตอบน้อยลง
- บริการ API คิดเงินตาม token

สำหรับคนทำงานทั่วไป: จำง่าย ๆ ว่า **1,000 token $\approx$ ข้อความ $\frac{3}{4}$ หน้า A4**

สามารถทดสอบนับ token ได้ที่: tiktokenizer.vercel.app

Context Window คืออะไร?

Context Window = "ความจำระยะสั้น" ของ AI — ข้อมูลทั้งหมดที่ AI มองเห็นในการสนทนาครั้งนั้น

ใส่ได้ทั้ง

- ข้อความบทสนทนาทั้งหมด
- เอกสารที่แนบ / วางข้อความ
- คำสั่งระบบ (System Prompt)

Gemini 2.0 รองรับ

- **1 ล้าน token** (~750,000 คำ)
- $\approx$ หนังสือ 10 เล่ม หรือโค้ด 30,000 บรรทัด
- เกิน limit $\rightarrow$ AI "ลืม" ส่วนต้น

💡 ถ้าสนทนาวานามากแล้ว AI เริ่มตอบผิดพลาด — ลองเปิด chat ใหม่และสรุป context ก่อน

LLM ช่วยงานข้อมูลอะไรได้บ้าง

ใน workflow จริง

- แปลงคำถามธุรกิจเป็น **SQL**
- ช่วยอ่านผล **EDA** และตั้ง hypothesis
- ดึงข้อมูลจากข้อความด้วย **extraction**
- ตรวจสอบความผิดปกติและช่วย reasoning เบื้องต้น
- สรุปผลเชิงเทคนิคให้เป็นภาษาที่สื่อสารกับทีมได้

คำถามหลักของคาบ: ใช้ AI ตรงไหนแล้วคุ้ม แต่ยังควบคุมคุณภาพได้?

ศัพท์สำคัญที่ต้องรู้ก่อนเริ่ม

คำที่เจอบ่อยในคาบนี้

- **Prompt:** ข้อความคำสั่งที่เราใช้สื่อสารกับโมเดล
- **Context:** ข้อมูลประกอบที่ใส่เพิ่มให้โมเดลตอบดีขึ้น
- **Hallucination:** โมเดลตอบอย่างมั่นใจ แต่ข้อเท็จจริงผิด
- **Human verification:** มนุษย์เป็นผู้ตรวจสอบคำตอบก่อนนำไปใช้จริง
- **Workflow:** ลำดับขั้นตอนของงานตั้งแต่รับข้อมูลจนสื่อสารผล

หลักง่าย

- prompt ที่ดี + context ที่พอ + การตรวจโดยคน = ใช้งานได้จริงมากขึ้น

หลักคิดก่อนใช้ LLM

AI เป็นผู้ช่วย ไม่ใช่ผู้ตัดสินใจสุดท้าย

- LLM เก่งเรื่อง pattern ของภาษา ไม่ได้ "รู้จริง" ทุกเรื่อง
- คำตอบที่สั้นไหลอาจยัง **ผิดเชิงข้อเท็จจริง** ได้
- งาน data ต้องมี **human verification** เสมอ
- ยิง prompt ชัด ยิงลดความคลุมเครือของ output

สิ่งที่ต้องตรวจสอบทุกครั้ง

- logic ถูกไหม
- data leakage หรือไม่
- ตัวเลขและ assumptions สอดคล้องโจทย์หรือไม่

Hallucination คืออะไร

อาการที่เจอได้บ่อย

- อ้างชื่อคอลัมน์ที่ไม่มีอยู่จริง
- เขียน SQL ที่ syntax ดูเหมือนถูก แต่รันไม่ได้
- สรุป insight ที่ไม่ได้รองรับจากข้อมูล
- อ้างเหตุผลเชิงธุรกิจเกินกว่าสิ่งที่ข้อมูลบอกได้

วิธีรับมือ

- ให้ schema หรือข้อมูลต้นทางชัดเจน
- ขอให้โมเดลระบุ assumptions
- ตรวจสอบด้วย code, query, หรือ domain knowledge จริง

ตัวอย่างงานในคาบนี้: อะไรคือ Generative AI

ตัวอย่างที่เราจะเห็นจริง

- ให้ LLM **สร้าง SQL** จากคำถามธุรกิจ
- ให้ LLM **สรุป EDA** จาก `describe()` และ missing values
- ให้ LLM **extract sentiment และ entities** จาก feedback
- ให้ LLM **ร่าง summary ภาษา business** จากผลวิเคราะห์

จุดร่วมของทุกตัวอย่าง

- โมเดลรับ input เป็นข้อความหรือข้อมูลที่แปลงเป็นข้อความ
- โมเดลสร้าง output ใหม่ในรูปแบบที่มนุษย์นำไปใช้ได้
- แต่ผลลัพธ์ยังต้องผ่านการตรวจโดยผู้วิเคราะห์เสมอ

02

Basic Prompt Engineering

Prompt คืออะไร?

Prompt = ประโยคที่คุณพิมพ์ให้ Gemini

ผลลัพธ์ดีหรือแย่ — ขึ้นอยู่กับ **วิธีที่คุณถาม** เป็นหลัก

สูตรพื้นฐาน

บริบท + งาน + รูปแบบที่ต้องการ

"คุณคือผู้ช่วยฝ่าย HR (บริบท) — ช่วยเขียนอีเมลแจ้งนโยบาย WFH ใหม่ให้พนักงาน (งาน) — โทนสุภาพ ความยาว 2 ย่อหน้า (รูปแบบ)"

ก่อน vs. หลัง ใส่ Prompt ที่ดี

Prompt แย่	Prompt ดี
"สรุปรายงานให้หน่อย"	"สรุปรายงานนี้เป็น 5 bullet points เน้น Action Items สำหรับผู้บริหาร"
"เขียนอีเมล"	"เขียนอีเมลทางการถึงลูกค้า เรื่องเลื่อนส่งงาน โทนขอโทษและมั่นใจ"
"แปลให้หน่อย"	"แปลข้อความนี้เป็นภาษาอังกฤษแบบ Business formal"

CO-STAR Framework คืออะไร?

CO-STAR คือกรอบการเขียน Prompt ที่พัฒนาโดย GovTech Singapore เพื่อช่วยให้ได้คำตอบจาก AI ที่ **ตรงความต้องการ**และนำไปใช้งานได้ทันที

ปัญหาที่แก้

- Prompt คลุมเครือ → คำตอบไม่ตรงใจ
- AI เดาเจตนาผิด → ต้องถามซ้ำหลายรอบ
- ผลลัพธ์ไม่เหมาะกับผู้ใช้

💡 ใช้งานได้กับทุก AI — Gemini, ChatGPT, Claude ฯลฯ

วิธีที่แก้

- ใส่ข้อมูล **6 มิติ** ให้ AI เข้าใจงานครบถ้วน
- ลด back-and-forth → ประหยัดเวลา
- ผลลัพธ์พร้อมใช้ตั้งแต่ครั้งแรก

สูตร CO-STAR Framework

ตัวอักษร	ความหมาย	ตัวอย่าง
Context	บริบทของงาน	"ฉันเป็น HR ในบริษัท 200 คน"
Objective	เป้าหมายที่ต้องการ	"ช่วยเขียนอีเมลแจ้งนโยบาย WFH"
Style	รูปแบบการเขียน	"เขียนแบบ Business formal"
Tone	โทนเสียง	"สุภาพ เป็นมิตร ไม่เป็นทางการเกินไป"
Audience	กลุ่มเป้าหมาย	"พนักงานทุกระดับ ไม่เชี่ยวชาญเทคนิค"
Response	รูปแบบผลลัพธ์	"ตอบเป็นอีเมล ความยาว 2 ย่อหน้า"

หลักการใช้ CO-STAR ให้ได้ผล

- **ไม่ต้องครบทุกตัวทุกครั้ง** — งานง่ายใช้แค่ C + O + R ก็พอ
 - **เรียง C → O ก่อนเสมอ** — AI ต้องรู้บริบทและเป้าหมายก่อนตอบ
 - **A (Audience) สำคัญมาก** — "สำหรับผู้บริหาร" vs "สำหรับพนักงานใหม่" ให้ผลต่างกันมาก
 - **T (Tone) ควบคุมน้ำเสียง** — เป็นทางการ / เป็นกันเอง / กระชับตรงประเด็น
- 💡 เริ่มจาก **C + O + R** ก่อน แล้วค่อยเพิ่ม S, T, A เมื่อผลลัพธ์ยังไม่ตรงที่ต้องการ

CO-STAR ในงานจริง — ตัวอย่าง

[C] ฉันเป็นเจ้าหน้าที่ฝ่ายประชาสัมพันธ์ของหน่วยงานราชการ

[O] ช่วยเขียนประกาศรับสมัครงานตำแหน่งนักวิเคราะห์นโยบาย

[S] เขียนแบบราชการ ถูกต้องตามรูปแบบ

[T] เป็นทางการ น่าเชื่อถือ

[A] ผู้สมัครที่จบปริญญาตรีขึ้นไป

[R] ตอบเป็นประกาศพร้อมใช้ ความยาว 1 หน้า A4

💡 ยิ่งให้ข้อมูลครบ — Gemini ยิ่งตอบตรงและนำไปใช้ได้ทันที

เทคนิค: Chain of Thought

ให้ AI "คิดทีละขั้น" ก่อนตอบ

เพิ่มประโยคนี้ในทุก Prompt ที่ต้องการความแม่นยำ:

"ลองคิดทีละขั้นตอน แล้วค่อยตอบ"

หรือ **"Let's think step by step"**

เหมาะกับ: การคำนวณ, การวิเคราะห์เหตุผล, การตัดสินใจซับซ้อน

CoT ปี 2026 — ยังต้องพิมพ์เองไหม?

Model	Reasoning อัตโนมัติ	ต้องสั่งเอง
Gemini 2.0 Flash Thinking	✅ คิดเองโดยไม่ต้องบอก	ไม่จำเป็น
Gemini 1.5 / GPT-4o	⚠️ คิดได้บ้าง	แนะนำสั่ง

💡 ถ้าใช้ **Gemini 2.0+** — เปิด "Thinking Mode" แทนการพิมพ์ "คิดทีละขั้น" ได้เลย

ทำอะไรแทน CoT ได้บ้าง?

- **เปิด Thinking Mode** — Gemini 2.0 Flash Thinking มี reasoning built-in
- **แบ่งถามทีละ step** — ถาม "วิเคราะห์ปัญหาก่อน" → แล้วค่อย "เสนอแนวทาง"
- **ใช้ CO-STAR ให้ครู** — O และ R ที่ชัดเจนช่วยให้ AI reasoning ดีขึ้นเอง

แทนที่: "วิเคราะห์สัญญาณนี้ให้หน่อย"

ใช้: "อ่านสัญญาณนี้ก่อน → แล้วบอกว่าข้อไหนเสี่ยง → พร้อมแนะนำว่าควรทำอะไร"

เทคนิค: Role Prompting

กำหนด "บทบาท" ให้ AI ก่อนถาม

"คุณคือ **นักกฎหมายผู้เชี่ยวชาญด้านสัญญา**

อ่านสัญญาต่อไปนี้และบอกจุดเสี่ยงที่ควรระวัง: [วางสัญญา]"

💡 Role ที่ดีช่วยให้ Gemini ใช้ "มุมมอง" ที่ถูกต้อง — ผลลัพธ์แม่นยำกว่ามาก

Role Prompting — ตัวอย่างในงานออฟฟิศ

Role ที่กำหนด	เหมาะกับงาน
"คุณคือนักสื่อสารองค์กรมืออาชีพ"	เขียนประกาศ อีเมล จดหมาย
"คุณคือวิทยากรที่สอนคนไม่เชี่ยวชาญ"	อธิบายเรื่องยากให้เข้าใจง่าย
"คุณคือบรรณาธิการภาษาไทย"	ตรวจแก้ภาษา ปรับโทนเนื้อหา
"คุณคือผู้จัดการโครงการที่มีประสบการณ์"	วางแผน ระบุความเสี่ยง ติดตามงาน


💡 เลือก Role ที่ **ไม่ขึ้นกับกฎหมายหรือข้อบังคับเฉพาะประเทศ** — ผลลัพธ์จะแม่นยำและเชื่อถือได้มากกว่า

Chat Template Structure คืออะไร?


ทุก Prompt ที่คุณส่ง จริงๆ แล้ว AI มองเห็นเป็น 3 ส่วน

ส่วน	คือ	ตัวอย่าง
System	คำสั่งตั้งต้น / บุคลิก AI	"คุณคือผู้ช่วยที่ตอบภาษาไทยเท่านั้น"
User	สิ่งที่คุณพิมพ์	Prompt ที่คุณส่งไป
Assistant	คำตอบของ AI	ข้อความที่ Gemini ตอบกลับ


💡 Role Prompting ที่เราใส่ใน Prompt คือการ "จำลอง System" — นั่นคือเหตุผลที่มันส่งผลต่อโทนและมุมมองของคำตอบ



รูปที่ 3.3: โครงสร้างของ Chat History แสดง System Message ที่อยู่ตอนต้นและมีความสำคัญสูงสุด ตามด้วยการสนทนาระหว่าง User และ AI ที่สะสมใน Context Window




รูปที่ 3.4: กลไกการทำงานของ Chat History คือ ทุกข้อความถูกส่งเข้า Context Window ซ้ำ ๆ ในทุกรอบ ทำให้การสนทนาเป็นไปอย่างต่อเนื่อง



หมายเหตุ: ทุกรอบการสนทนา ระบบส่ง Chat History ทั้งหมดเข้า Context Window → ข้อผิดพลาดจะสะสมและแพร่กระจาย

รูปที่ 3.5: กลไกการทำงานของ Chat History คือ ทุกข้อความถูกส่งเข้า Context Window ซ้ำ ๆ ในทุกรอบ หาก Prompt แรกผิด ความผิดจะติดตามไปในทุกคำตอบถัดไป



รูปที่ 3.6: การแก้ไข Prompt ที่ผิดพลาดต้องทำที่ต้นทาง เพื่อป้องกันการสะสมข้อผิดพลาดในบริบทที่ส่งเข้าโมเดลในรอบถัดไป

Workshop 1 — Prompt ก่อน/หลัง

ลองทำ (10 นาที)

1. เลือกงานที่ทำบ่อยในชีวิตประจำวัน
2. เขียน Prompt แบบสั้นๆ ก่อน → ดูผลลัพธ์
3. ปรับ Prompt ด้วยสูตร **CO-STAR** → เปรียบเทียบ

คำถามชวนคิด: ผลลัพธ์ต่างกันอย่างไร?

ตัวอย่างเริ่มต้น:

- Prompt สั้น: "เขียนอีเมลขอเลื่อนนัดประชุม"
- Prompt CO-STAR: "[C] ฉันเป็นเจ้าหน้าที่ธุรการ [O] เขียนอีเมลขอเลื่อนนัดประชุมกับลูกค้า [S] ทางการ [T] สรุภาพ ขอโทษอย่างจริงใจ [A] ลูกค้าระดับผู้บริหาร [R] อีเมล 1 ย่อหน้า"

03

Data Analysis with Gemini

การวิเคราะห์ข้อมูลด้วย Gemini

- เราสามารถใช้ Gemini ช่วยวิเคราะห์ข้อมูลได้หลายรูปแบบ เช่น
 - วิเคราะห์แนวโน้มและความแตกต่างระหว่างกลุ่มประชากร
 - ตรวจสอบความผิดปกติของข้อมูล
 - สรุปผลเชิงสถิติและสร้างกราฟประกอบ
 - สร้างโค้ด SQL หรือ Python สำหรับการวิเคราะห์ต่อไป
 - สรุปผลเชิงนโยบายจากข้อมูลที่วิเคราะห์แล้ว
- แต่ **ต้องมี Human Verification** ทุกครั้ง
- Gemini ช่วย "คิดไว" แต่คนต้อง "คุณภาพ"

ภาพรวมกระบวนการวิเคราะห์ด้วย LLM/Gemini

Workflow: Data Analysis with LLM

จากข้อมูลดิบสู่ข้อเสนอเชิงนโยบาย




Workshop 2 — การวิเคราะห์ข้อมูลขนาดเล็กด้วย Gemini

1. ดาวน์โหลดไฟล์ presidents.csv ที่
https://github.com/toche7/DataSets/blob/main/president_heights.csv
2. เปิดใช้งาน gemini.google.com
3. เปิด chat ใหม่และ add ไฟล์ president_heights.csv ที่ดาวน์โหลดจาก GitHub
4. พิมพ์ prompt เช่น

ช่วยวิเคราะห์ข้อมูลความสูงของประธานาธิบดีในไฟล์นี้ และตอบคำถามต่อไปนี้: ความสูงเฉลี่ย ความสูงมากที่สุด และน้อยสุด พร้อมสร้างกราฟการกระจายความสูงด้วย

ตัวอย่างผลลัพธ์ที่ได้จาก Gemini

Show code <>



Python Code ที่ Gemini สร้างให้

Python

Hide code



```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Load dataset
df = pd.read_csv('president_heights.csv')

print("Columns:", df.columns)
print(df.head())

# Calculate statistics
mean_height = df['height(cm)'].mean() if 'height(cm)' in df.columns else df.iloc[:, -1]
max_height = df['height(cm)'].max() if 'height(cm)' in df.columns else df.iloc[:, -1]
min_height = df['height(cm)'].min() if 'height(cm)' in df.columns else df.iloc[:, -1]

# Identify highest and lowest presidents
height_col = 'height(cm)' if 'height(cm)' in df.columns else df.columns[-1]
name_col = 'name' if 'name' in df.columns else df.columns[1]
```

การวิเคราะห์ข้อมูลขนาดใหญ่ด้วย Gemini

ในการวิเคราะห์ข้อมูลขนาดใหญ่ (เช่น ข้อมูลประชากร) เราสามารถใช้ Gemini ช่วยวิเคราะห์ได้ แต่ต้องระวังเรื่อง **Context Window** และ **Token Limit** ของโมเดล ความซ้ำซ้อนของข้อมูล และความถูกต้องของผลลัพธ์ ต้องมีการตรวจสอบโดยมนุษย์ (Human Verification) ทุกครั้ง และควรมี workflow ที่ชัดเจนในการวิเคราะห์ข้อมูล เช่น

- การทำ Data Cleansing
- การตรวจสอบความถูกต้องของข้อมูล
- การสร้าง Prompt ที่เหมาะสม
- การสรุปผลเชิงนโยบายจากข้อมูลที่วิเคราะห์แล้ว

ในส่วนต่อไปนี้จะ เราจะใช้ตัวอย่างข้อมูลจริงจาก **อัตราการมีงานทำต่อประชากรวัยแรงงาน** ของสำนักงานสถิติแห่งชาติ (NSO) เพื่อฝึกการวิเคราะห์ข้อมูลด้วย Gemini

Dataset: อัตราการมีงานทำต่อประชากรวัยแรงงาน (NSO)

- ชุดข้อมูล: data.go.th - 0706 02 0011
- หน่วย: **ร้อยละ**
- แหล่งข้อมูล: **สำรวจภาวะการทำงานของประชากร**
- ช่วงปีข้อมูล: **2558-2563**
- มิติที่มีให้จำแนก: **เพศ / กลุ่มอายุ / ระดับการศึกษา / อุตสาหกรรม**

ตัวอย่างข้อมูลจริง (Raw Data)

	_id	year	quarter	region	area	level_of_edu	value	unit	source
1	1	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	รวม	66.97	ร้อยละ	สำนักงานสถิติแห่งชาติ
2	2	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	01. ไม่มีการศึกษา	50.11	ร้อยละ	สำนักงานสถิติแห่งชาติ
3	3	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	02. ต่ำกว่าประถมศึกษา	44.43	ร้อยละ	สำนักงานสถิติแห่งชาติ
4	4	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	03. ประถมศึกษา	73.94	ร้อยละ	สำนักงานสถิติแห่งชาติ
5	5	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	04. มัธยมศึกษาตอนต้น	64	ร้อยละ	สำนักงานสถิติแห่งชาติ
6	6	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	05. มัธยมศึกษาตอนปลาย สายสามัญ	71.28	ร้อยละ	สำนักงานสถิติแห่งชาติ
7	7	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	06. มัธยมศึกษาตอนปลาย สายอาชีวศึกษา	69.79	ร้อยละ	สำนักงานสถิติแห่งชาติ
8	8	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	07. มัธยมศึกษาตอนปลาย สายวิชาการศึกษา	73.33	ร้อยละ	สำนักงานสถิติแห่งชาติ
9	9	2567	ไตรมาส 1	ทั่วราชอาณาจักร	รวม	08. อุดมศึกษาสายวิชาการ	82.01	ร้อยละ	สำนักงานสถิติแห่งชาติ

ตัวอย่างคอลัมน์ที่ใช้ใน workshop: `year` , `quarter` , `region` , `area` , `level_of_edu` , `value`

Workflow: Data Analysis with Gemini

1. **Define Policy Question:** ตั้งคำถามเชิงนโยบาย เช่น กลุ่มไหนเสี่ยงตกงาน
2. **Load NSO Table:** เลือกตารางจาก resource ที่ต้องการ (ภาพรวม/เพศ-อายุ/การศึกษา)
3. **Ask Structured Analysis:** ให้ Gemini สรุปแนวโน้ม, ความต่างรายกลุ่ม, จุดผิดปกติ
4. **Human Verify:** ตรวจสอบเลขจริงก่อนแปลผลเชิงนโยบาย

หลักง่าย: Gemini ช่วย "คิดไว้" แต่คนต้อง "ควบคุมภาพ"

Prompt Template สำหรับโจทย์นี้

Context: ฉันเป็นนักวิเคราะห์ข้อมูลภาครัฐด้านแรงงาน

Task: วิเคราะห์แนวโน้มและความแตกต่างระหว่างกลุ่มประชากร

Output: ตอบ 3 ส่วน: Insight | Evidence | Policy Recommendation

แนบไฟล์ CSV ที่ดาวน์โหลดจาก data.go.th (อัตราการมีงานทำต่อประชากรวัยแรงงาน)

ข้อควรระวังข้อมูลชุดนี้

- ควรทำการ cleansing แถวข้อมูลส่วนที่มี region "ทั่วราชอาณาจักร" หรือ "ทั่วประเทศ", area "รวม", และ level_of_edu "รวม" ออกไปจากข้อมูลก่อนวิเคราะห์ เพราะเป็นข้อมูลรวมที่ไม่จำแนกกลุ่มย่อย เมื่อนำไปคำนวณจะทำให้เกิดการ double counting และ skewed result ได้

Human Verification Checklist

ก่อนนำคำตอบไปใช้จริง ให้เช็ก 5 ข้อนี้:

1. ตัวเลขตรงกับข้อมูลต้นทางหรือไม่
2. มีการสรุปเกินกว่าที่ข้อมูลรองรับหรือไม่
3. ความสัมพันธ์ถูกต้องความเป็นเหตุและผลหรือไม่
4. มีปัจจัยแทรกซ้อนที่ยังไม่ได้ใส่ในข้อมูลหรือไม่
5. ข้อเสนอแนะสอดคล้องกับบริบทหน่วยงานจริงหรือไม่

Workshop 3 — วิเคราะห์ข้อมูลด้วย Gemini

ลองทำ (12 นาที)

1. ใช้ข้อมูลจาก https://data.go.th/dataset/0706_02_0011?id=585e5552-8ecf-445c-be16-a97140018169
2. เขียน Prompt ด้วยโครง: Context + Indicator + Data + Task + Output + Constraint
3. ให้ Gemini สรุป Insight 3 ข้อ และข้อเสนอแนะเชิงนโยบาย 2 ข้อ
4. ใช้ Checklist ตรวจสอบภาพก่อนสรุปผล

ตรวจสอบผลที่ได้จาก Gemini ด้วย Checklist ต่อไปนี้:

- เปรียบเทียบผลที่ได้กับเพื่อนข้างเคียง วิเคราะห์ความแตกต่าง
- ตรวจสอบว่ามีการนำซ้ำหรือไม่ และให้เหตุผลว่าทำไมถึงเป็นเช่นนั้น
- ตรวจสอบความถูกต้องของการวิเคราะห์

จาก Insight ไปสู่ Dashboard ด้วย Canvas

ทำไมต้อง Canvas

- เปลี่ยนผลวิเคราะห์ให้เป็นภาพที่ผู้บริหารอ่านเร็ว
- ปรับข้อความ + กราฟ + KPI ได้ในพื้นที่เดียว
- ใช้ Gemini ช่วยร่างโครง dashboard ได้ทันที

เป้าหมาย: สื่อสารการตัดสินใจ ไม่ใช่แค่โชว์กราฟ

โครงสร้าง Dashboard ที่แนะนำ (1 หน้า)

1. **KPI Cards:** ค่าเฉลี่ยอัตราการมีงานทำ, ค่าสูงสุด, ค่าต่ำสุด
2. **Trend Chart:** แนวโน้มปี 2558-2563
3. **Segment Compare:** เปรียบเทียบเพศ/กลุ่มอายุ/การศึกษา
4. **Policy Notes:** ข้อเสนอแนะ 2-3 ข้อจากข้อมูล

💡 ให้ทุกกราฟตอบคำถามเดียวกัน: "กลุ่มไหนควรเป็นเป้าหมายเร่งด่วน"

Prompt: ให้ Gemini ช่วยออกแบบ Dashboard Canvas

คุณเป็น Data Storytelling Assistant ช่วยออกแบบ Dashboard แบบหน้าเดียวสำหรับตัวชี้วัด
"อัตราการมีงานทำต่อประชากรวัยแรงงาน"

สิ่งที่ต้องมี:

1. กราฟแนวโน้ม 1 กราฟ
2. กราฟเปรียบเทียบกลุ่ม 1 กราฟ
3. Insight และข้อเสนอแนะเชิงนโยบาย 3 ข้อ

ตอบเป็นโครง Canvas: Section | วัตถุประสงค์ | Visualization | ข้อความประกอบ

ในแบบไฟล์ CSV และ เลือกใช้ Canvas ด้วย

Checklist คุณภาพ Dashboard

1. ตัวเลขใน KPI ตรงกับตารางต้นทางหรือไม่
2. แกนกราฟและหน่วย "ร้อยละ" แสดงชัดหรือไม่
3. สีและ label ไม่ทำให้ตีความผิดหรือไม่
4. Insight สอดคล้องกับสิ่งที่เห็นในกราฟหรือไม่
5. ข้อเสนอแนะเชิงนโยบายเชื่อมกับหลักฐานจริงหรือไม่


Workshop 4 — สร้าง Dashboard บน Canvas

ลองทำเพิ่ม (15 นาที)

1. ใช้ข้อมูลจาก https://data.go.th/dataset/0706_02_0011?id=585e5552-8ecf-445c-be16-a97140018169
2. ให้ Gemini ออกแบบโครงสร้าง Dashboard Canvas 1 หน้า
3. ปรับข้อความ Insight ให้เหมาะกับผู้บริหารหน่วยงาน

คำถามชวนคิด: Dashboard นี้ช่วยตัดสินใจ "มาตรการใด" ได้ชัดเจน?

ตัวอย่าง Dashboard Canvas ที่ Gemini ช่วยร่าง



Key Takeaways

- ใช้ Gemini เพื่อเร่งขั้นตอนวิเคราะห์ ไม่ใช่แทนผู้วิเคราะห์
- Prompt ที่ชัด + Context ที่เพียงพอ + Human Verification = ผลลัพธ์ที่ใช้งานได้จริง
- ข้อมูลที่มีความซับซ้อน และมีขนาดใหญ่ ควรใช้เครื่องมืออื่นเช่น Colab หรือ Jupyter Notebook ร่วมกับ Gemini

Q&A

วิทยากร

ผศ.ดร.ทวิศักดิ์ สมานชื่น

Asst. Prof. Taweesak Samanchuen, Ph.D.

- รองผู้อำนวยการฝ่ายดิจิทัลเทคโนโลยี **MULKC**
- อาจารย์ประจำสาขา **ITM** คณะวิศวกรรมศาสตร์ มหาวิทยาลัยมหิดล
- หัวหน้าโครงการ **CBTU**

 [Profile](#)

 t.samanchuen@gmail.com

 081-441-4906

website: cbtumu.net | facebook: [cbtumu](https://www.facebook.com/cbtumu)

ขอบคุณครับ

ผศ.ดร.ทวีศักดิ์ สمانชื่น