

Session 03

Data Visualization with Gemini in Colab

หลักสูตร: การใช้ Generative AI เพื่อการวิเคราะห์ข้อมูลสำหรับภาครัฐ

Asst. Prof. Taweesak Samanchuen, Ph.D.

Mahidol University

วัตถุประสงค์ของ Session

เมื่อจบช่วงนี้ ผู้เข้าอบรมสามารถ:

1. เลือกประเภทกราฟให้เหมาะกับชนิดข้อมูลและเป้าหมาย
2. ใช้ Gemini in Colab ช่วยออกแบบและสร้างกราฟได้รวดเร็วขึ้น
3. อธิบายความสัมพันธ์ของตัวแปรด้วย correlation และ regression เบื้องต้น
4. ตีความผลจากกราฟอย่างถูกต้องและชัดเจน
5. สื่อสารข้อมูลให้ผู้บริหารและผู้เกี่ยวข้องเข้าใจได้ง่าย

ภาพรวมเนื้อหา

1. Recall: สิ่งที่เราเรียนไปแล้วใน Session 01-02
2. Univariate และ Bivariate Analysis
3. Correlation และ Regression
4. Visualization เพื่อการสื่อสาร
5. Workshop 6: Data Visualization with Gemini in Colab
6. LLM for Data Extraction

1. Recall

1) Recall

- AI and ML
- Colab with AI
- Basic Python for Data Analysis
- Data Preprocessing
- EDA

2. Univariate and Bivariate Analysis

Univariate Analysis

การวิเคราะห์ตัวแปรเดียว


- วิเคราะห์ตัวแปรทีละตัว โดยไม่คำนึงถึงความสัมพันธ์กับตัวแปรอื่น
- เป้าหมาย: ทำความเข้าใจการกระจาย (distribution), ค่ากลาง, และ outlier
- กราฟที่ใช้: Histogram, Boxplot, Bar chart

สถิติ	ความหมาย
Mean / Median	ค่ากลางของข้อมูล
Std Dev	ความผันแปรของข้อมูล
Min / Max	ขอบเขตของข้อมูล

ตัวอย่าง Univariate Analysis

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
# สถิติพื้นฐาน
print(df.describe())
# Histogram
sns.histplot(df["Passenger"], bins=6, kde=True)
plt.title("Number of Passenger")
plt.show()
```


Univariate Analysis: Histogram



Univariate Analysis: Boxplot

- Boxplot แสดงค่ากลาง (median), quartiles, และ outliers ของข้อมูล - ช่วยให้เห็นการกระจายและความไม่สมมาตรของข้อมูล

```
sns.boxplot(data=df, x="Passenger")  
plt.title("Boxplot of Passenger")  
plt.show()
```



Bivariate Analysis

การวิเคราะห์ความสัมพันธ์ระหว่าง 2 ตัวแปร


- วิเคราะห์ว่าตัวแปร 2 ตัวมีความสัมพันธ์กันอย่างไร
- เป้าหมาย: หารูปแบบ (pattern) และแนวโน้มร่วมกัน
- กราฟที่ใช้: Scatter plot, Box plot แยกกลุ่ม, Heatmap

ชนิดข้อมูล	วิธีวิเคราะห์
Numeric + Numeric	Scatter plot, Correlation
Numeric + Categorical	Boxplot, Grouped Bar chart
Categorical + Categorical	Crosstab, Heatmap

ตัวอย่าง Bivariate Analysis

```
# Scatter plot: Passenger vs Fuel Cost
sns.scatterplot(data=df, x="Passenger", y="Fuel Cost")
plt.title("Passenger vs Fuel Cost")
plt.show()


# Correlation matrix
print(df[["Passenger", "Fuel Cost"]].corr())
```



3. Correlation and Regression

Correlation

- Correlation (สหสัมพันธ์) เป็นการวิเคราะห์ความสัมพันธ์ระหว่างข้อมูลตั้งแต่ 2 ตัวขึ้นไปว่ามีความสัมพันธ์กันในระดับใด และมีความสัมพันธ์ในทิศทางใด
- เช่น ความสูงกับน้ำหนักของคน มีความสัมพันธ์กันมากหรือน้อยและมีความสัมพันธ์ในทิศทางเดียวกันหรือตรงกันข้าม



Correlation Coefficient

- Correlation Coefficient คือค่าสถิติอย่างง่ายที่ใช้แสดงความสัมพันธ์ระหว่างข้อมูล ว่ามีค่ามาก น้อยเพียงใดและอยู่ในทิศทางใด
- โดยมีสูตรพื้นฐานที่ใช้กันคือ Pearson Product Moment Correlation Coefficient




$$r = \frac{cov(X, Y)}{(std(X) * std(Y))} \quad (1)$$

$$r = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \quad (2)$$

จะใช้ pearson correlation เมื่อข้อมูลเป็น continuous และมีความสัมพันธ์เชิงเส้น ถ้าเป็น categorical จะใช้ spearman correlation หรือ chi-square test แทน

Correlation Coefficient Interpretation

- ค่า r ใกล้ 1 = ไปทิศทางเดียวกัน
- ค่า r ใกล้ -1 = สวนทางกัน
- ค่า r ใกล้ 0 = ความสัมพันธ์เชิงเส้นน้อย



ตัวอย่างการคำนวณ Correlation ด้วย Python


```
import pandas as pd
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
correlation = df["Passenger"].corr(df["Fuel Cost"])
print(f"Correlation between Passenger and Fuel Cost: {correlation:.2f}")
```

Regression

ใช้สร้างสมการทำนาย

$$\hat{y} = \theta_0 + \theta_1 \cdot x_1$$

- θ_1 บอกว่า $\hat{y}$ (Fuel Cost) เปลี่ยนเท่าไรเมื่อ x_1 (Passenger) เพิ่ม 1 หน่วย
- ใช้สื่อสารแนวโน้มและประมาณค่าได้อย่างรวดเร็ว
- ควรตรวจ outlier และ residual ก่อนนำไปใช้จริง



ตัวอย่างโค้ด

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
url = "https://github.com/toche7/DataSets/raw/refs/heads/main/cost.xlsx"
df = pd.read_excel(url)
X = df[["Passenger"]]
y = df["Fuel Cost"]
model = LinearRegression().fit(X, y)
sns.regplot(data=df, x="Passenger", y="Fuel Cost", line_kws={"color": "red"}, ci=98)
plt.title(f"Passenger vs Fuel Cost ( R2= {model.score(X, y):.2f} )")
plt.show()
```

Prompt ที่แนะนำ

ใช้ไฟล์ `cost.xlsx` จาก GitHub นี้

- 1) โหลดข้อมูลด้วย pandas
- 2) สร้าง scatter plot และ regression line
- 3) คำนวณ correlation ระหว่าง Passenger กับ Fuel Cost
- 4) อธิบายผลเป็นภาษาไทยแบบที่ใช้สอนผู้เรียนได้

จุดที่ให้ผู้เรียนสังเกต

- เมื่อ Passenger เพิ่มขึ้น Fuel Cost เปลี่ยนอย่างไร
- เส้น regression อธิบายข้อมูลได้ดีแค่ไหน
- ความสัมพันธ์ที่เห็นเป็นเหตุผลหรือเพียงความสัมพันธ์

4. Visualization เพื่อการสื่อสาร

แพลตฟอร์มที่ใช้ในชั้นเรียน

1. Gemini in Colab: ช่วยคิด วิเคราะห์ และเขียนโค้ดในโน้ตบุ๊กเดียว
2. GitHub Raw CSV: ใช้เป็นแหล่งข้อมูลกลางให้ทุกคนโหลดข้อมูลชุดเดียวกัน
3. Visualization Libraries: ใช้ `pandas`, `matplotlib`, `seaborn`

1) หลักการเลือกประเภทกราฟ


คำถามก่อนเลือกกราฟ

- ต้องการเปรียบเทียบ, แสดงแนวโน้ม, หรือแสดงสัดส่วน?
- ข้อมูลเป็นหมวดหมู่, ตัวเลขต่อเนื่อง, หรือเวลา?
- ผู้ชมต้องการตัดสินใจเรื่องใดจากกราฟนี้?


แนวทางใช้งาน

- Bar chart: เปรียบเทียบค่าระหว่างกลุ่ม
- Line chart: แนวโน้มตามเวลา
- Scatter plot: ความสัมพันธ์ระหว่างตัวแปร
- Heatmap: รูปแบบ/ความเข้มข้นในหลายมิติ


Bar chart: เปรียบเทียบค่าระหว่างกลุ่ม




Line chart: แนวโน้มตามเวลา




Pie chart: แสดงสัดส่วนของแต่ละกลุ่มในภาพรวม



Scatter plot: ความสัมพันธ์ระหว่างตัวแปร



Heatmap: รูปแบบ/ความเข้มข้นในหลายมิติ



ตัวอย่าง: คำถามแบบไหน ใช้กราฟอะไร

ใช้ชุดข้อมูลผู้รับบริการภาครัฐรายเดือน

คำถาม	กราฟที่เหมาะสม	สิ่งที่อยากเห็น
จังหวัดไหนมีผู้รับบริการมากที่สุดในเดือนล่าสุด	Bar chart	เปรียบเทียบขนาดระหว่างจังหวัด
จำนวนผู้รับบริการเพิ่มหรือลดลงอย่างไรใน 6 เดือน	Line chart	แนวโน้มและจังหวะการเปลี่ยนแปลง
เวลารอที่ลดลง ทำให้ความพึงพอใจสูงขึ้นหรือไม่	Scatter plot	ความสัมพันธ์ระหว่าง 2 ตัวแปร
จังหวัดใดมีจำนวนผู้รับบริการสูงต่อเนื่องหลายเดือน	Heatmap	จุดที่เข้ม/อ่อนในหลายมิติ

ตัวอย่างการตีความจากข้อมูลเดียวกัน

ตัวอย่างข้อความสรุปที่ “ดีพอสำหรับนำเสนอ”

- Bar chart: กรุงเทพมหานครมีผู้รับบริการสูงสุดในเดือนล่าสุด จึงอาจต้องจัดทรัพยากรหน้าจุดบริการมากกว่าจังหวัดอื่น
- Line chart: ทุกจังหวัดมีแนวโน้มผู้รับบริการเพิ่มขึ้นต่อเนื่อง สะท้อนว่าความต้องการบริการยังขยายตัว
- Scatter plot: เมื่อเวลาลดลง ความพึงพอใจมีแนวโน้มสูงขึ้น แต่ยังไม่พอจะสรุปว่าเป็นเหตุโดยตรง
- Heatmap: เชียงใหม่และกรุงเทพมหานครมีความเข้มสูงหลายเดือนต่อเนื่อง จึงควรติดตามกำลังคนและช่องทางออนไลน์ควบคู่กัน

สิ่งที่ต้องระวัง

- อย่าสรุปว่า “เวลาลดลงทำให้ความพึงพอใจสูงขึ้นแน่นอน” โดยไม่มีปัจจัยอื่นประกอบ
- อย่าดูเฉพาะจังหวัดที่ค่าสูงสุด แต่ให้ดูอัตราการเปลี่ยนแปลงและบริบทของพื้นที่ด้วย

2) Data Visualization เพื่อการสื่อสาร

หลักการสำคัญ

- ชัดเจน: ลดองค์ประกอบที่ไม่จำเป็น
- ถูกต้อง: ไม่บิดเบือนสเกลหรือบริบท
- มีสาร: ทุกกราฟต้องตอบคำถามหลักได้

โครงสร้างการเล่าเรื่องข้อมูล

1. บริบทของปัญหา
2. หลักฐานจากข้อมูล
3. Insight และข้อเสนอแนะ

กรณีศึกษาประสิทธิภาพการบริการ


1. บริบทของปัญหา (Context)

เราต้องการตรวจสอบว่า 'จำนวนผู้รับบริการที่เพิ่มขึ้น ส่งผลกระทบต่อคุณภาพการบริการและความพึงพอใจหรือไม่' เพื่อวางแผนการจัดการทรัพยากรในอนาคต

2. หลักฐานจากข้อมูล (Evidence)

ใช้กราฟที่เน้นความ ชัดเจน โดยลด Grid lines ที่ไม่จำเป็น และเน้นความ ถูกต้อง ของสเกล

Case Study: การสื่อสารข้อมูลด้วย Visualization



3) ใช้ Gemini in Colab ช่วยสร้างกราฟ

ตัวอย่างการใช้งาน

- ช่วยร่างโค้ดสร้างกราฟจากตารางข้อมูล
- แนะนำกราฟที่เหมาะสมกับตัวแปรแต่ละชุด
- ช่วยปรับแต่ง label/title/annotation ให้ชัดเจน
- สร้างสรุปข้อความประกอบกราฟอัตโนมัติ

Prompt ที่แนะนำ

Prompt ที่แนะนำ

จากข้อมูลนี้ ช่วยเสนอ 3 กราฟที่เหมาะสม พร้อมเหตุผล และตัวอย่างโค้ด

Prompt ตัวอย่างที่ชัดเจน

ข้อมูลนี้เป็นจำนวนผู้รับบริการภาครัฐรายเดือน แยกตามจังหวัด

ช่วยเลือกกราฟที่เหมาะสม 4 แบบ โดยอธิบายว่ากราฟแต่ละแบบตอบคำถามผู้บริหารอะไรได้

และเขียนโค้ด Python ที่พร้อมรันใน Colab"

4) การตีความกราฟอย่างมีคุณภาพ

เช็กलिस्टก่อนสรุปผล

- ความแตกต่างที่เห็นมีนัยสำคัญเชิงปฏิบัติหรือไม่
- มีปัจจัยแทรกซ้อนที่ยังไม่ถูกควบคุมหรือไม่
- ข้อสรุปสอดคล้องกับนิยามตัวชี้วัดหรือไม่
- มีข้อจำกัดข้อมูลที่ต้องแจ้งหรือไม่

ข้อผิดพลาดที่พบบ่อย

- สรุปเหตุ-ผลจากความสัมพันธ์เพียงอย่างเดียว
- ใช้กราฟ 3D หรือเอฟเฟกต์ที่ทำให้ตีความคลาดเคลื่อน

5. Workshop 6: Data Visualization with Gemini in Colab

Workshop 6

 Open in Colab

กิจกรรมฝึกปฏิบัติ

1. เลือกคำถามวิเคราะห์จาก Session 02
2. ออกแบบกราฟอย่างน้อย 3 แบบ
3. ใช้ Gemini in Colab ช่วยสร้าง/ปรับโค้ด
4. สรุปข้อความ insight ต่อกราฟละ 1-2 ประโยค

ผลลัพธ์ที่คาดหวัง

- ชุดกราฟที่พร้อมนำเสนอ
- ข้อความอธิบายที่กระชับและใช้งานได้จริง

ติดตั้ง font ภาษาไทยใน Colab

Prompt

ช่วยเขียนโค้ด Python ใน Colab เพื่อดาวน์โหลดและติดตั้งฟอนต์ภาษาไทยที่เหมาะสมกับการสร้างกราฟใน Matplotlib และทดสอบการแสดงผลด้วยข้อความภาษาไทย

- เลือก model ที่มีเก่งในการทำเรื่องนี้เพราะมีความซับซ้อนในการจัดการฟอนต์และการแสดงผลภาษาไทยในกราฟ ซึ่งอาจต้องใช้ความรู้เฉพาะทางในการตั้งค่าฟอนต์ใน Matplotlib และการจัดการกับภาษาไทยใน Python โดยตรง
- ให้เลือกฟอนต์ที่นิยมใช้สำหรับการนำเสนอในภาษาไทย เช่น "TH Sarabun New" หรือ "Kanit" และช่วยเขียนโค้ดที่พร้อมรันได้เลยใน Colab เพื่อให้ผู้เรียนสามารถใช้ฟอนต์นี้ในการสร้างกราฟและแสดงผลภาษาไทยได้อย่างถูกต้อง

ติดตั้ง font ภาษาไทยใน Colab

```
# ดาวน์โหลดฟอนต์ TH Sarabun New
!wget -q https://github.com/Phonbopit/sarabun-webfont/raw/master\
/fonts/thсарunnew-webfont.ttf
import matplotlib as mpl
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# เพิ่มฟอนต์เข้าระบบ Matplotlib
fm.fontManager.addfont('thсарunnew-webfont.ttf')
# ตั้งค่า default font ให้เป็น TH Sarabun New
mpl.rc('font', family='TH Sarabun New')
```

ทดสอบการแสดงผลภาษาไทย

```
# ทดสอบการพล็อตภาษาไทย
plt.figure(figsize=(6, 4))
plt.text(0.5, 0.5, 'สวัสดีภาษาไทย (Thai Language Test)', fontsize=25, ha='center', va='center')
plt.title('ทดสอบการแสดงผลภาษาไทย')
plt.axis('off')
plt.show()
```

ผลลัพธ์ที่คาดหวัง

ทดสอบการแสดงผลภาษาไทย

สวัสดีภาษาไทย (Thai Language Test)

Workshop 6: โหลดข้อมูลจาก GitHub

Dataset สำหรับฝึก

- Raw CSV: <https://raw.githubusercontent.com/toche7/DataSets/main/session-03-workshop-sample-data.csv>
- แพลตฟอร์มหลัก: Gemini in Colab
- เครื่องมือ: `pandas`, `matplotlib`, `seaborn`
- ใช้ชุดข้อมูลเดียวกันเพื่อสร้างกราฟ 4 ประเภท

Prompt ที่ให้ผู้เรียนใช้

โหลดข้อมูลจากไฟล์ CSV นี้ และช่วยสร้างกราฟ 4 ประเภท ได้แก่ bar chart, line chart, scatter plot และ heatmap แยก เป็นภาพ ๆ พร้อมอธิบายว่าแต่ละกราฟตอบคำถามเชิงนโยบายอะไรได้บ้าง และช่วยปรับชื่อกราฟ แขน และสีให้เหมาะกับการนำเสนอผู้บริหาร:

python code ตัวอย่างการโหลดข้อมูลและเริ่มต้นวิเคราะห์

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
url = "https://raw.githubusercontent.com/toche7/DataSets/main/session-03-workshop-sample-data"
df = pd.read_csv(url)
df["เดือน"] = pd.to_datetime(df["เดือน"])
sns.set_theme(style="whitegrid")
df.head()
```

ตัวอย่าง 1-2: Bar และ Line

Bar chart: เปรียบเทียบจังหวัดในเดือนล่าสุด

```
latest = df[df["เดือน"] == df["เดือน"].max()]
sns.barplot(data=latest, x="จังหวัด", y="จำนวนผู้รับบริการทั้งหมด(คน)")
plt.xticks(rotation=15)
plt.title("จำนวนผู้รับบริการทั้งหมด แยกตามจังหวัด")
plt.show()
```

Line chart: แนวโน้มรายเดือนของผู้รับบริการ

```
sns.lineplot(data=df, x="เดือน", y="จำนวนผู้รับบริการทั้งหมด(คน)", hue="จังหวัด", marker="o")
plt.title("แนวโน้มผู้รับบริการรายเดือน")
plt.show()
```

ตัวอย่าง 3-4: Scatter และ Heatmap

Scatter plot: เวลารอกับความพึงพอใจ

```
sns.scatterplot(data=df, x="เวลารอเฉลี่ย(นาที)", y="ความพึงพอใจ(%)", hue="จังหวัด", s=120)
plt.title("ความสัมพันธ์ระหว่างเวลารอและความพึงพอใจ")
plt.show()
```

Heatmap: ผู้รับบริการตามเดือนและจังหวัด

```
pivot = df.pivot(index="จังหวัด", columns="เดือน", values="จำนวนผู้รับบริการทั้งหมด(คน)")
sns.heatmap(pivot, cmap="YlGnBu", annot=True, fmt=".0f")
plt.title("Heatmap จำนวนผู้รับบริการ")
plt.show()
```

Prompt ให้ Gemini ช่วยต่อยอด

> ใช้ Gemini in Colab กับข้อมูลจากไฟล์ CSV นี้เพื่อสร้าง bar chart, line chart, scatter plot และ heatmap พร้อมอธิบายว่าแต่ละกราฟตอบคำถามเชิงนโยบายอะไรได้บ้าง และช่วยปรับชื่อกราฟ แกน และสีให้เหมาะกับการนำเสนอผู้บริหาร

จุดที่ให้ผู้เรียนสังเกต

- จังหวัดใดมีปริมาณผู้รับบริการสูงสุดอย่างสม่ำเสมอ
- เวลาที่ลดลงสัมพันธ์กับความพึงพอใจหรือไม่
- จังหวัดใดมีโอกาสเพิ่มสัดส่วนบริการออนไลน์ได้อีก

6. LLM for Data Extraction

Workshop 7: LLM for Data Extraction

 Open in Colab

GitHub: <https://github.com/toche7/SlideAIDATADGA/blob/main/slides/workshop-07-llm-data-extraction-groq.ipynb>

กิจกรรมฝึกปฏิบัติ

1. ตั้งค่า Groq API key ใน Colab
2. Extract ข้อมูลแบบมีโครงสร้างจากข้อความที่ไม่มีโครงสร้าง
3. ทำ Sentiment Analysis เป็น positive/neutral/negative
4. สรุปผลลัพธ์เป็นตารางสำหรับนำเสนอ

Unstructured Data Extraction

- We can use LLM to extract structured data from unstructured data sources such as PDF, Word, and Excel files.
- Moreover, we can use LLM to do sentiment analysis, topic modeling, and text summarization.

Connect with LLM for Data Extraction

- We can connect to LLM for example Groq.com
- We are going to use Colab to connect to LLM for data extraction and analysis.
- We need to install the required libraries and set up the API key for authentication.
- We have to apply to Groq.com to get the API key and set it up in Colab.

Demo: Connecting to LLM for Data Extraction

Sentiment Analysis with LLM

- We can use LLM to analyze the sentiment of text data. For example, we can analyze customer reviews, social media posts, and survey responses.
- We can use LLM to classify the sentiment as positive, negative, or neutral.

Demo: Sentiment Analysis with LLM

Q&A

เตรียมต่อ Session 04: AI-Assisted Reporting and Presentation

วิทยากร

ผศ.ดร.ทวิศักดิ์ สมานชื่น

Asst. Prof. Taweesak Samanchuen, Ph.D.

- รองผู้อำนวยการฝ่ายดิจิทัลเทคโนโลยี **MULKC**
- อาจารย์ประจำสาขา **ITM** คณะวิศวกรรมศาสตร์ มหาวิทยาลัยมหิดล
- หัวหน้าโครงการ **CBTU**

 [Profile](#)

 t.samanchuen@gmail.com

 081-441-4906

website: cbtumu.net | facebook: [cbtumu](https://www.facebook.com/cbtumu)

ขอบคุณครับ

ผศ.ดร.ทวีศักดิ์ สمانชื่น